UNIVERSIDADE FEDERAL DO RIO GRANDE DO NORTE
DEPARTAMENTO DE COMPUTAÇÃO E TECNOLOGIA
BACHARELADO EM SISTEMAS DE INFORMAÇÃO

DCT1401 – INTELIGÊNCIA ARTIFICIAL
Professor: Thommas K. S. Flores

ISABELLE CAVALCANTI DA SILVA

ANÁLISE EXPLORATÓRIA E PREPARAÇÃO DE DADOS PARA MODELOS DE APRENDIZADO DE MÁQUINA

Atividade Prática Avaliativa

Matrícula: 20250031684

Dataset:
EV Battery Failure Prediction Dataset (200K)
https:
//www.kaggle.com/datasets/sarveshchhetri/ev-battery-failure-prediction-dataset-200k

Repositório GitHub:
https://github.com/Isabellecavalcant/projeto-ia-ev-battery.git

Caicó – RN
2026

SUMÁRIO

1 INTRODUÇÃO 2

2 ANÁLISE EXPLORATÓRIA 3
2.1 Valores ausentes 3
2.2 Detecção de outliers 4
2.3 Correlação e multicolinearidade 6

3 LIMPEZA E PRÉ-PROCESSAMENTO 8

4 PERCEPÇÕES PARA REGRESSÃO 9
4.1 Escolha e distribuição da variável alvo 9
4.2 Relação entre features e target 10
4.3 Percepções e recomendações para modelagem 13

5 PERCEPÇÕES PARA CLASSIFICAÇÃO 14
5.1 Escolha e distribuição da variável alvo 14
5.2 Relação entre features e target 14
5.3 Análise das variáveis por classe 15
5.4 Testes estatísticos 18
5.5 Uso em frota e uso privado 19
5.6 Percepções e recomendações para modelagem 19

6 CONSIDERAÇÕES FINAIS 21

7 REFERÊNCIA AO REPOSITÓRIO 22

1 INTRODUÇÃO

Este relatório apresenta a análise exploratória, a limpeza e o pré-processamento do conjunto de dados *EV Battery Failure Prediction Dataset (200K)*, com o objetivo de preparar os dados e obter percepções que possam orientar a construção de modelos de aprendizado de máquina para dois problemas supervisionados: regressão e classificação.

O conjunto de dados contém 200.000 registros e 70 variáveis relacionadas a veículos elétricos e suas baterias. Entre os atributos disponíveis estão informações relacionadas à condição da bateria, temperatura, ciclos de carga, tensão, capacidade, utilização do veículo e características operacionais.

Para o problema de regressão, foi selecionada como variável alvo predicted_rema ining_life_cycles, que representa a estimativa da quantidade restante de ciclos de vida da bateria. Para o problema de classificação, foi utilizada a variável battery_failure, que representa a ocorrência ou não de falha da bateria.

2 ANÁLISE EXPLORATÓRIA

A análise exploratória foi iniciada pela inspeção das primeiras e últimas observações, das dimensões do conjunto de dados e dos tipos das variáveis. Também foram analisadas estatísticas descritivas para os atributos numéricos e frequências para os atributos categóricos.

O conjunto de dados possui 200.000 observações e 70 colunas. Foram identificadas 59 variáveis do tipo `float64`, uma variável do tipo `int64` e dez variáveis do tipo `object`.

Entre as variáveis categóricas estão características como marca e modelo do veículo, tipo de veículo, fabricante e química da bateria, tipo de tração, tipo de utilização e terreno.

Também foram identificadas as colunas vehicle_id e battery_serial, utilizadas como identificadores.

2.1 Valores ausentes

Foram encontrados valores ausentes em 67 variáveis. Entretanto, os percentuais observados foram relativamente baixos, situando-se majoritariamente entre aproximadamente 3% e 5%.

A variável com maior percentual de ausência foi fast_charge_ratio, com aproximadamente 4,94% de valores ausentes. Outras variáveis com percentuais próximos foram average_speed, com aproximadamente 4,92%, manufacturing_year, com 4,91%, e home_charging_ratio, com 4,90%.

A variável alvo utilizada posteriormente na regressão, predicted_remaining_life_cycles, apresentou 8.974 valores ausentes, correspondendo a aproximadamente 4,49% das observações.

A Figura 1 apresenta a distribuição percentual dos valores ausentes.

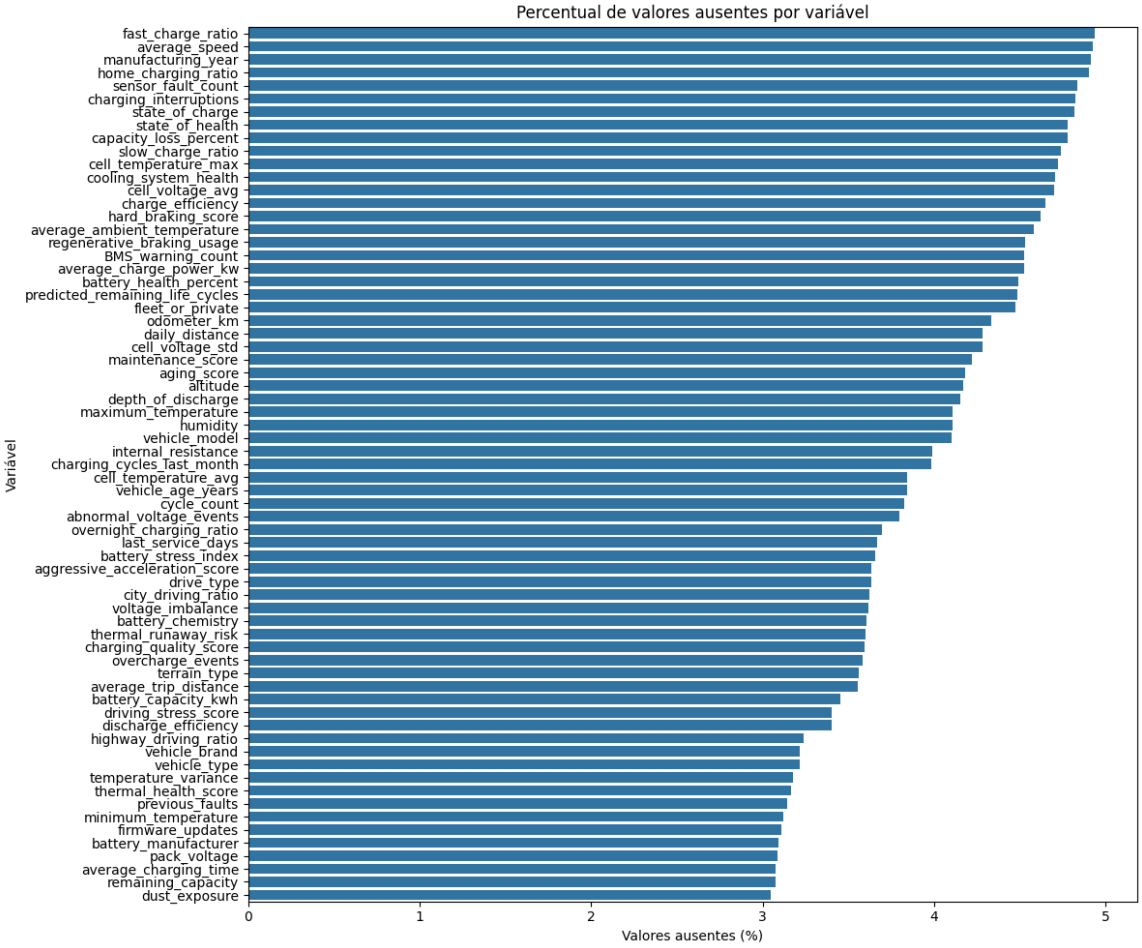


Figura 1 – Percentual de valores ausentes por variável.

Fonte: elaboração própria (2026).

Como não foram identificadas colunas com percentuais excessivos de ausência, optou-se por preservar as variáveis e tratar esses valores durante a etapa de pré-processamento.

2.2 Detecção de outliers

A identificação de outliers foi realizada por meio do método do intervalo interquartil (IQR), complementado pela inspeção visual das distribuições por meio de boxplots.

Entre as variáveis que apresentaram maior proporção de valores identificados como outliers estão average_charging_time, com aproximadamente 6,49%, cycle_count, com 4,27%, last_service_days, com 4,21%, e pack_voltage, com 3,53%.

A Figura 2 apresenta o primeiro conjunto de variáveis analisadas por meio de boxplots.

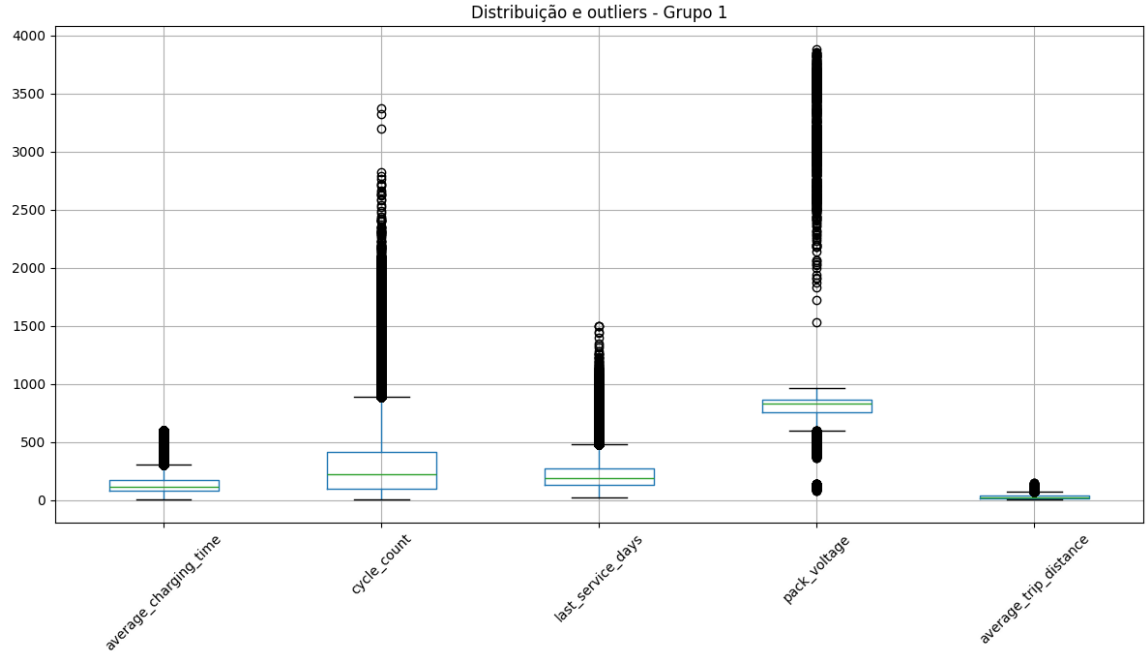


Figura 2 – Análise de outliers no primeiro grupo de variáveis numéricas.

Fonte: elaboração própria (2026).

A Figura 3 apresenta um segundo conjunto de variáveis, permitindo observar outros valores considerados extremos pelo critério do IQR.

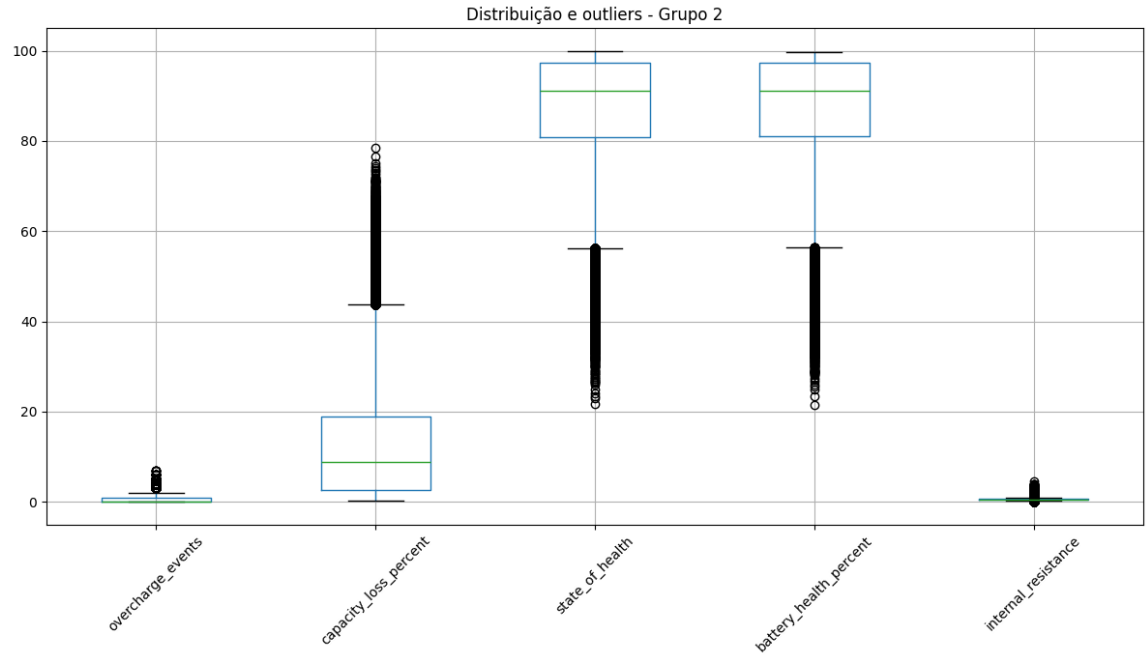


Figura 3 – Análise de outliers no segundo grupo de variáveis numéricas.

Fonte: elaboração própria (2026).

Apesar da identificação estatística desses valores, decidiu-se não realizar sua remoção

indiscriminada. Considerando o domínio analisado, valores extremos podem representar condições reais de operação, desgaste ou degradação das baterias e, consequentemente, podem carregar informações relevantes para modelos futuros.

2.3 Correlação e multicolinearidade

A matriz de correlação foi calculada para as variáveis numéricas com o objetivo de identificar relações lineares relevantes e possíveis situações de multicolinearidade.

A Figura 4 apresenta a matriz de correlação obtida.

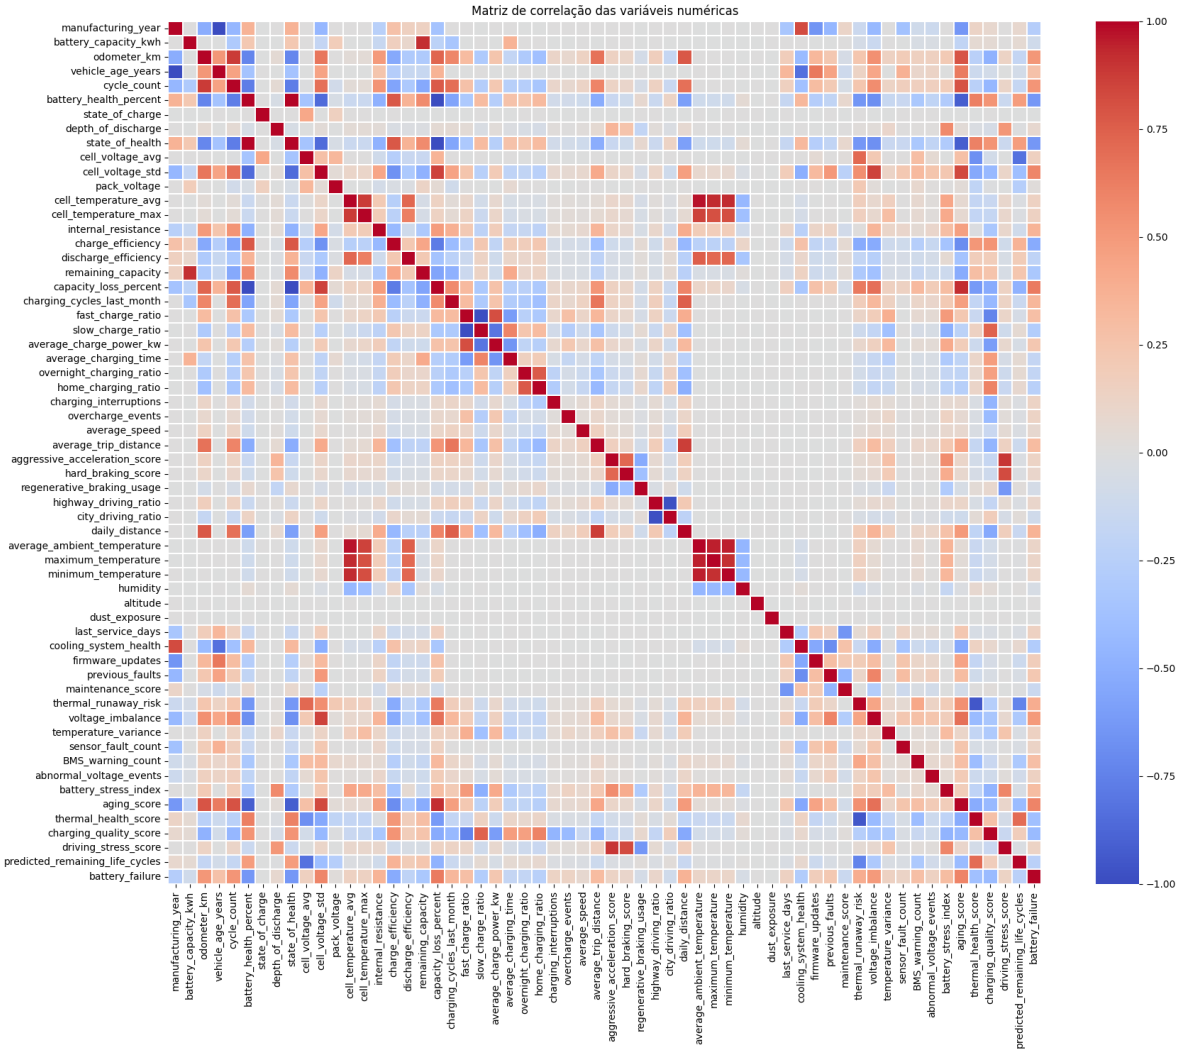


Figura 4 – Matriz de correlação das variáveis numéricas.

Fonte: elaboração própria (2026).

Foram observadas correlações muito elevadas entre alguns atributos. A correlação entre battery_health_percent e capacity_loss_percent foi aproximadamente $-1,00$.

Também foi identificada correlação de aproximadamente $-0,999$ entre manufacturing_year e vehicle_age_years.

Outras relações relevantes incluem a correlação entre state_of_health e capacity_loss_percent, de aproximadamente $-0,994$, entre battery_health_percent e state_of_health, de aproximadamente $0,994$, e entre fast_charge_ratio e slow_charge_ratio, de aproximadamente $-0,987$.

Esses resultados indicam a presença de multicolinearidade no conjunto de dados. Algumas variáveis carregam informações muito semelhantes, aspecto que deve ser considerado na seleção de atributos e na escolha dos modelos.

3 LIMPEZA E PRÉ-PROCESSAMENTO

A etapa de pré-processamento foi realizada separadamente para os problemas de regressão e classificação, mantendo as decisões de tratamento consistentes com as características identificadas durante a análise exploratória.

As colunas vehicle_id e battery_serial foram removidas do conjunto de features, pois funcionam como identificadores individuais e não representam características adequadas para a generalização dos modelos.

Para as variáveis numéricas com valores ausentes foi utilizada imputação pela mediana. Essa estratégia foi escolhida por ser menos sensível à influência de valores extremos quando comparada à média.

Para as variáveis categóricas foi utilizada imputação pela categoria mais frequente, ou moda.

As variáveis categóricas foram transformadas utilizando *One-Hot Encoding*. Essa técnica representa cada categoria por meio de variáveis binárias, sem estabelecer uma ordem artificial entre as categorias.

Diferentemente do *Label Encoding*, que atribui valores numéricos inteiros às categorias, o *One-Hot Encoding* é mais adequado neste caso por se tratar predominantemente de atributos nominais.

Para as variáveis numéricas foi aplicada padronização utilizando `StandardScaler`. O procedimento transforma as variáveis considerando sua média e desvio padrão, evitando que diferenças de escala influenciem excessivamente algoritmos sensíveis à magnitude dos atributos.

Os outliers identificados na análise exploratória foram mantidos, pois podem representar condições reais de utilização e degradação das baterias. Sua remoção indiscriminada poderia eliminar informações potencialmente relevantes para a previsão da vida útil e da ocorrência de falhas.

Os dados foram divididos em conjuntos de treinamento e teste na proporção de 80% e 20%.

Para a classificação, a divisão foi realizada de forma estratificada em relação a battery_failure, preservando a proporção das classes.

Para evitar vazamento de informação entre os dois problemas, a variável battery_fail ure não foi utilizada como feature da regressão e a variável predicted_remaining_life_cycles não foi utilizada como feature da classificação.

Os transformadores responsáveis pela imputação, codificação e padronização foram ajustados somente sobre os dados de treinamento, evitando que informações provenientes do conjunto de teste influenciassem o pré-processamento.

4 PERCEPÇÕES PARA REGRESSÃO

4.1 Escolha e distribuição da variável alvo

A variável escolhida para o problema de regressão foi predicted_remaining_life_cycles. Essa variável representa a estimativa da quantidade restante de ciclos de vida da bateria e constitui uma variável numérica adequada para um problema de regressão.

Após a remoção das observações que não apresentavam valor para essa variável, permaneceram 191.026 registros disponíveis para a análise.

A variável alvo apresentou média de aproximadamente 1.859,49 ciclos, desvio padrão de aproximadamente 1.834,36 ciclos, mediana de 1.245 ciclos, valor mínimo de 0 e máximo de 15.474 ciclos, além de 5.169 valores distintos.

Esses resultados demonstram ampla variabilidade da variável.

A Figura 5 apresenta sua distribuição.

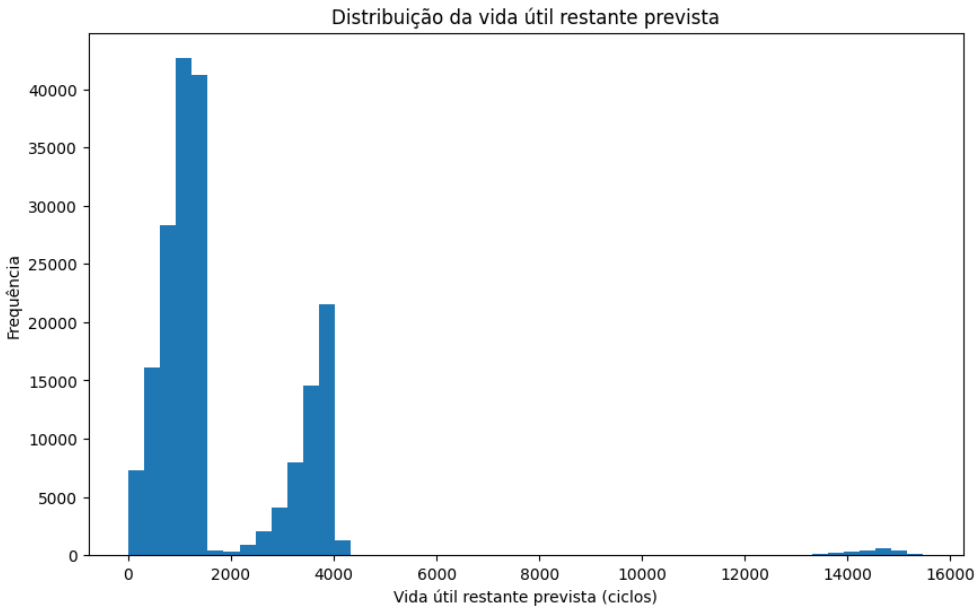


Figura 5 – Distribuição da variável alvo do problema de regressão.

Fonte: elaboração própria (2026).

A distribuição apresenta concentração maior em determinados intervalos e uma extensão considerável em direção aos valores mais elevados.

Essa característica indica que a modelagem pode envolver relações não lineares e que diferentes métricas devem ser consideradas na avaliação dos modelos.

4.2 Relação entre features e target

A correlação entre as variáveis numéricas e predicted_remaining_life_cycles foi utilizada como uma primeira medida para identificar atributos potencialmente relevantes.

A maior correlação em módulo foi observada para cell_voltage_avg, com aproximadamente $-0,827$.

Também apresentaram relações relevantes thermal_runaway_risk $(-0,736)$, thermal_health_score $(0,698)$, capacity_loss_percent $(-0,484)$, battery_health_percent $(0,484)$ e state_of_health $(0,479)$.

A Figura 6 apresenta as principais correlações encontradas.

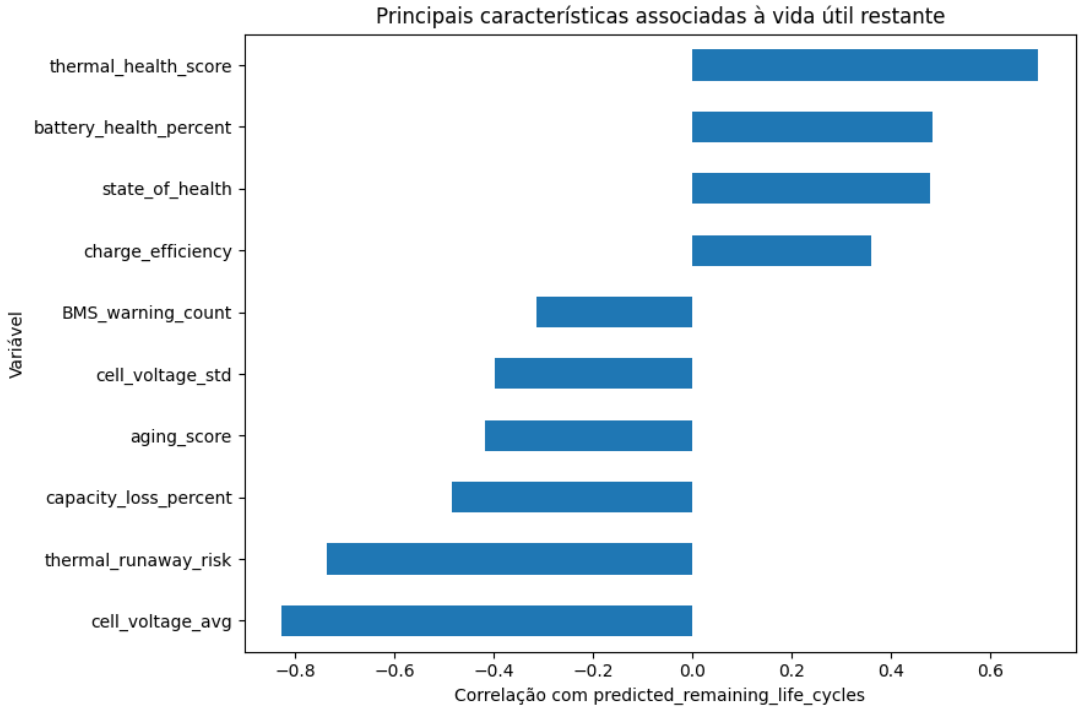


Figura 6 – Principais correlações com a variável alvo da regressão.

Fonte: elaboração própria (2026).

Além dos coeficientes de correlação, foram utilizados gráficos de dispersão para observar diretamente o comportamento das três variáveis que apresentaram as relações mais fortes com o target.

A Figura 7 apresenta a relação entre a tensão média das células e a quantidade prevista de ciclos restantes.

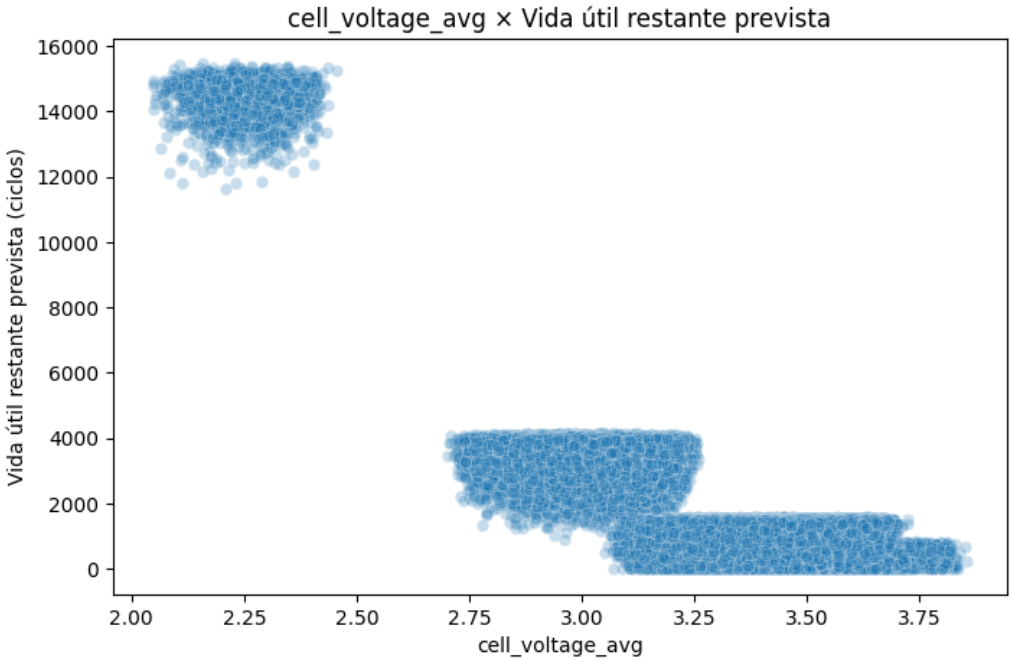


Figura 7 – Relação entre tensão média das células e vida útil restante da bateria.

Fonte: elaboração própria (2026).

Observa-se uma associação negativa entre a tensão média das células e a variável alvo, consistente com o coeficiente de correlação calculado.

A Figura 8 apresenta a relação entre o risco de fuga térmica e a estimativa de ciclos restantes.

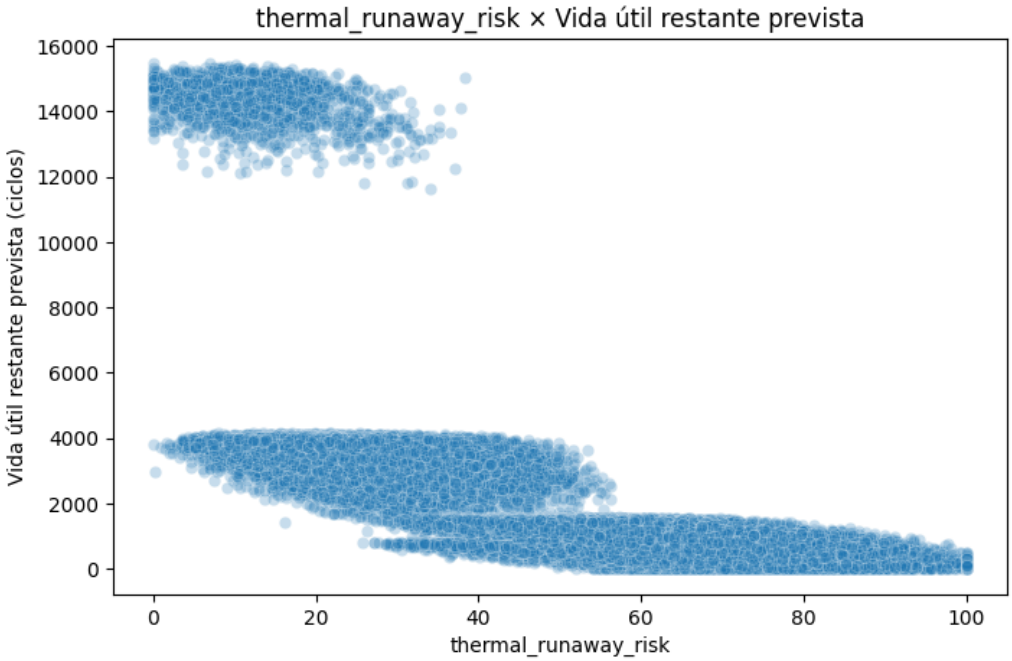


Figura 8 – Relação entre risco térmico e vida útil restante da bateria.

Fonte: elaboração própria (2026).

O aumento do risco térmico apresenta associação com a redução da quantidade estimada de ciclos restantes.

A Figura 9 apresenta a relação entre o indicador de saúde térmica e o target da regressão.

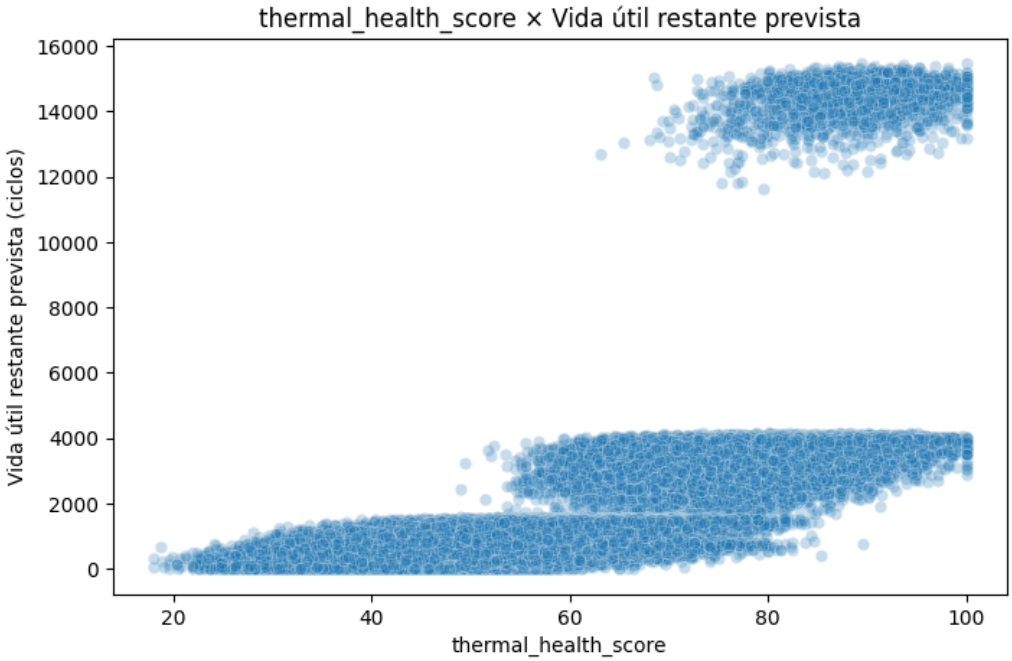


Figura 9 – Relação entre saúde térmica e vida útil restante da bateria.

Fonte: elaboração própria (2026).

Nesse caso, observa-se uma associação positiva: valores mais elevados do indicador de saúde térmica tendem a estar associados a uma maior quantidade prevista de ciclos restantes.

Os gráficos de dispersão complementam a análise de correlação e reforçam a relevância de características relacionadas à tensão e à condição térmica da bateria. Entretanto, as correlações identificadas não devem ser interpretadas isoladamente como relações causais.

4.3 Percepções e recomendações para modelagem

Com base na análise realizada, recomenda-se considerar inicialmente atributos como cell _voltage_avg, thermal_runaway_risk, thermal_health_score, capacity_loss_percent, battery_health_percent, state_of_health, aging_score e charge_efficiency.

Entre os principais desafios estão a presença de relações potencialmente não lineares e a forte multicolinearidade identificada entre determinadas features.

A existência de atributos altamente redundantes deve ser considerada durante a seleção de variáveis.

Como modelos iniciais, podem ser avaliados Regressão Linear, utilizada como baseline, Random Forest Regressor e métodos de Gradient Boosting.

Para comparar os modelos, podem ser utilizadas métricas como MAE, RMSE e coeficiente de determinação (R^2).

5 PERCEPÇÕES PARA CLASSIFICAÇÃO

5.1 Escolha e distribuição da variável alvo

Para o problema de classificação, foi selecionada a variável battery_failure. Essa variável já está presente no conjunto de dados e representa diretamente a ocorrência ou não de falha da bateria, sendo 0 associado à ausência de falha e 1 à ocorrência de falha.

Foram observados 180.079 registros da classe 0, correspondendo a aproximadamente 90,04% das observações, e 19.921 registros da classe 1, correspondendo a aproximadamente 9,96%.

A Figura 10 apresenta a distribuição das duas classes.

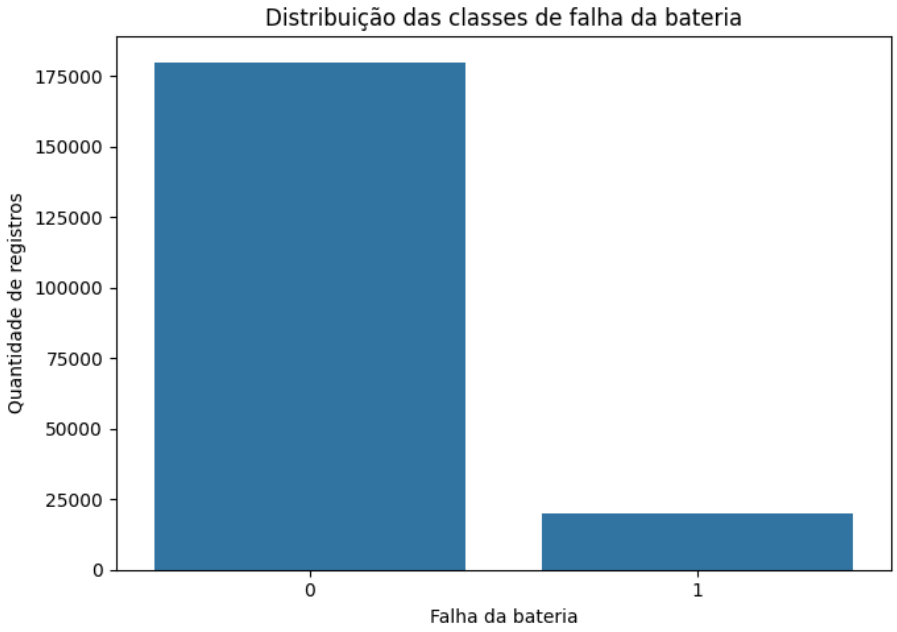


Figura 10 – Distribuição das classes do problema de classificação.

Fonte: elaboração própria (2026).

Observa-se um desbalanceamento expressivo entre as duas classes.

Esse resultado é particularmente importante para uma futura etapa de modelagem, pois um classificador que privilegie a classe majoritária pode apresentar alta acurácia mesmo com baixo desempenho na identificação das falhas.

5.2 Relação entre features e target

Inicialmente, foram calculadas as correlações entre as variáveis numéricas e battery_failure.

Os maiores coeficientes em módulo foram observados para capacity_loss_percent $(0,639)$, battery_health_percent $(-0,638)$, state_of_health $(-0,636)$, aging_score $(0,598)$ e cell_voltage_std $(0,590)$.

A Figura 11 apresenta as principais correlações encontradas.

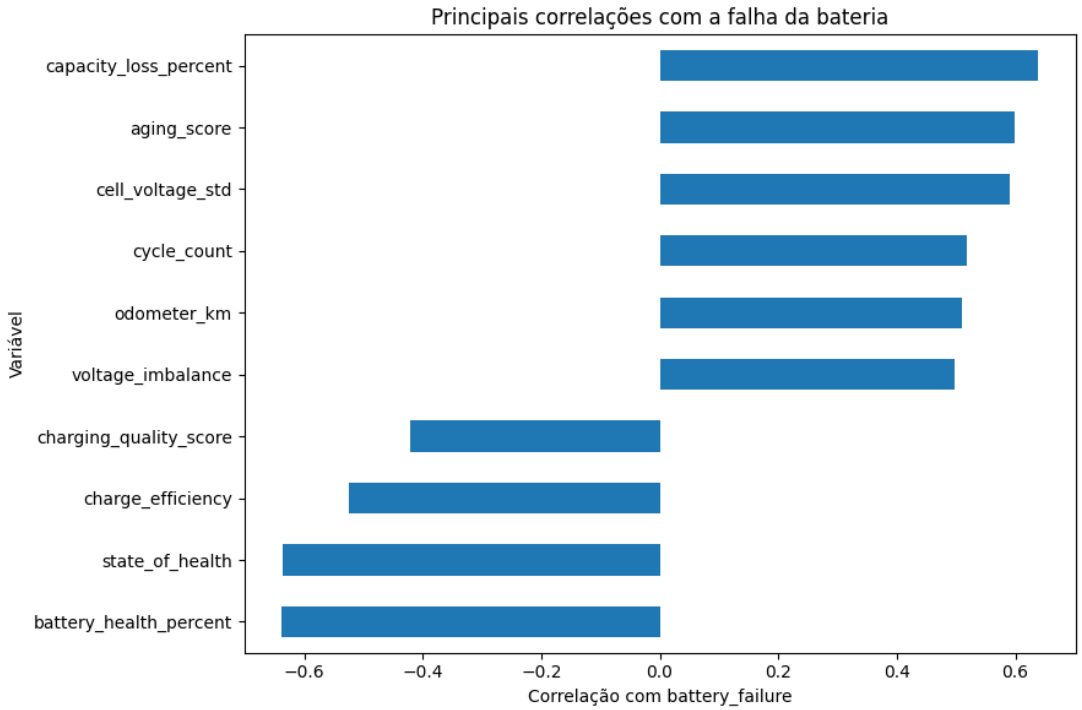


Figura 11 – Principais correlações com a variável alvo da classificação.

Fonte: elaboração própria (2026).

Os resultados sugerem que a ocorrência de falha está particularmente associada a características relacionadas à degradação, saúde, envelhecimento e comportamento elétrico da bateria.

5.3 Análise das variáveis por classe

Para complementar a análise de correlação, foram utilizados boxplots para comparar a distribuição de variáveis importantes entre as classes com e sem falha.

A Figura 12 apresenta a distribuição da perda percentual de capacidade.

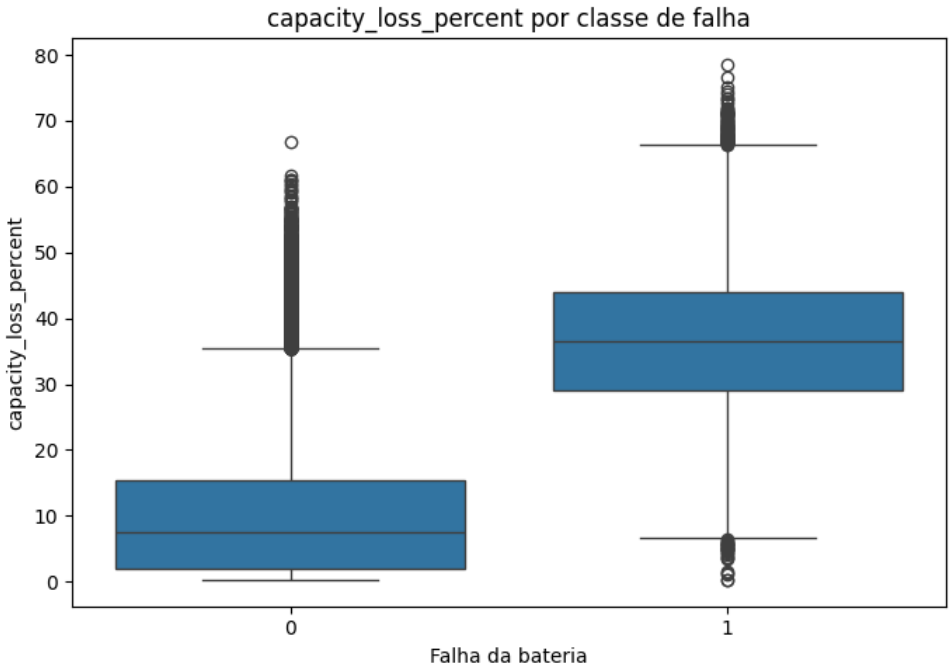


Figura 12 – Distribuição da perda de capacidade segundo a ocorrência de falha.

Fonte: elaboração própria (2026).

Observa-se que baterias pertencentes à classe de falha apresentam, em geral, valores mais elevados de perda de capacidade.

A Figura 13 apresenta a distribuição do percentual de saúde da bateria entre as classes.

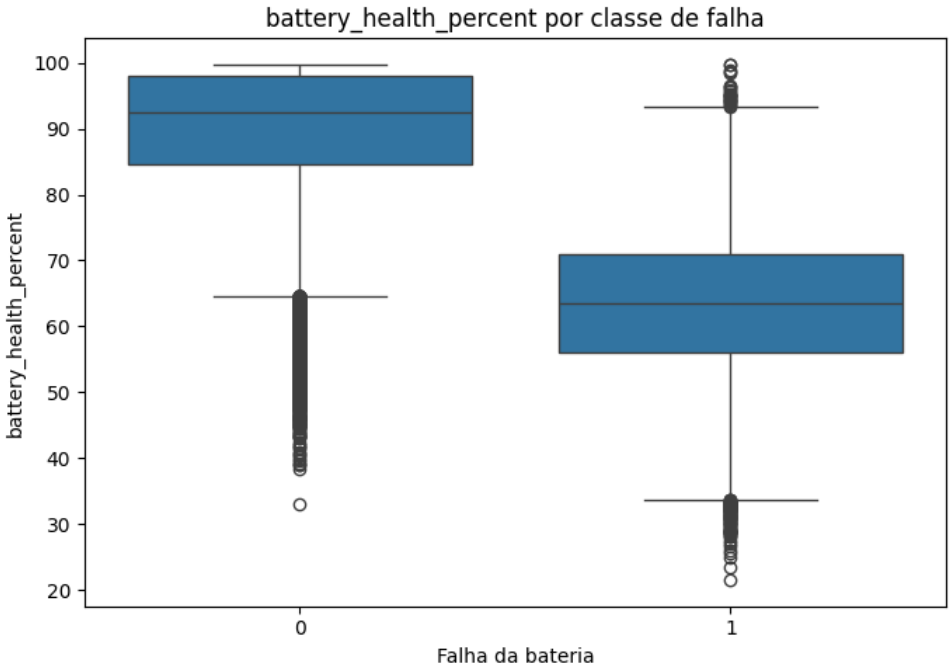


Figura 13 – Distribuição da saúde da bateria segundo a ocorrência de falha.

Fonte: elaboração própria (2026).

Baterias classificadas como falha apresentam, de maneira geral, valores inferiores do indicador de saúde.

A Figura 14 apresenta a distribuição do estado de saúde da bateria.

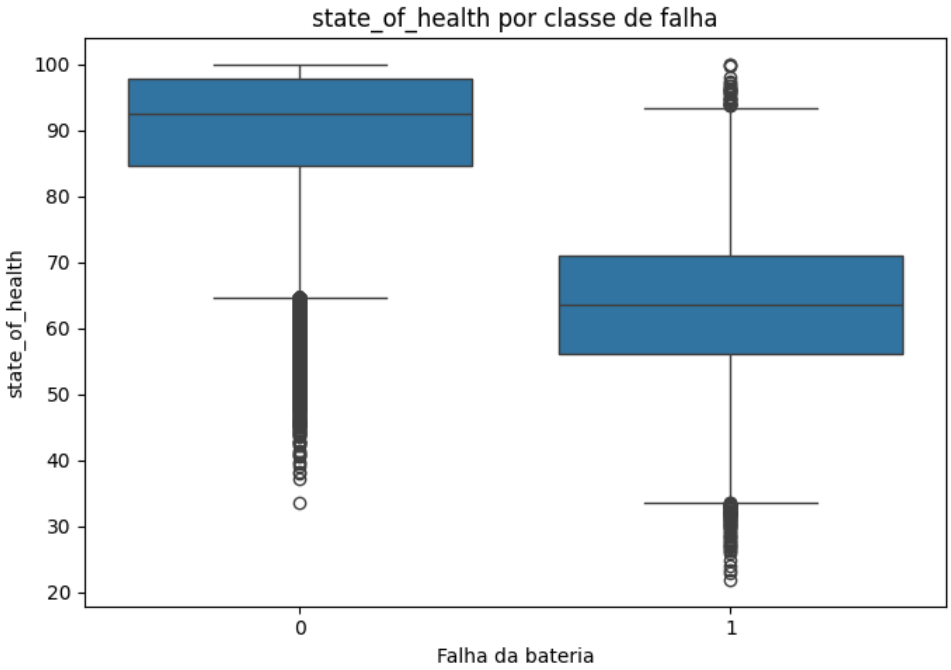


Figura 14 – Distribuição do estado de saúde segundo a ocorrência de falha.

Fonte: elaboração própria (2026).

As diferenças observadas nos três boxplots reforçam a relevância das características relacionadas à degradação e saúde da bateria para a classificação.

5.4 Testes estatísticos

Para complementar as análises visuais e verificar a existência de diferenças estatisticamente significativas entre as classes, foi aplicado o teste ANOVA às principais variáveis numéricas.

Foram obtidos valores de $p < 0,001$ para capacity_loss_percent, battery_health _percent, state_of_health, aging_score e cell_voltage_std.

Dessa forma, foram identificadas diferenças estatisticamente significativas entre as classes para essas características.

Para as variáveis categóricas foi aplicado o teste qui-quadrado.

Foram identificadas associações estatisticamente significativas entre battery_failure e as variáveis vehicle_brand, vehicle_model, vehicle_type, battery_chemistry e fleet_or_private.

Por outro lado, battery_manufacturer, drive_type e terrain_type não apresentaram evidências estatísticas equivalentes de associação com o target no teste realizado.

5.5 Uso em frota e uso privado

Entre as variáveis categóricas analisadas, fleet_or_private apresentou uma diferença particularmente expressiva na ocorrência de falhas.

A taxa de falha observada foi de aproximadamente 26,29% para veículos pertencentes a frotas e de aproximadamente 3,60% para veículos de uso privado.

A Figura 15 apresenta essa comparação.

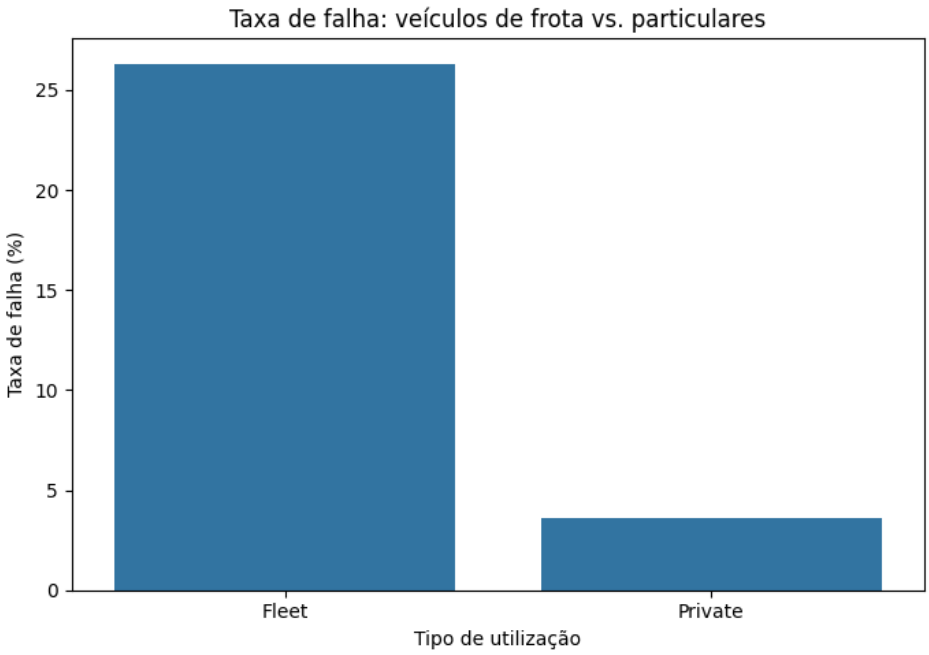


Figura 15 – Taxa de falha segundo o tipo de utilização do veículo.

Fonte: elaboração própria (2026).

A diferença observada indica que o contexto de utilização do veículo está associado à ocorrência de falha e sugere que fleet_or_private pode contribuir para a capacidade preditiva de um futuro classificador.

Entretanto, essa associação não deve ser interpretada isoladamente como uma relação causal.

5.6 Percepções e recomendações para modelagem

Com base nas análises realizadas, recomenda-se considerar inicialmente características como capacity_loss_percent, battery_health_percent, state_of_health, aging_score, cell_voltage_std, cycle_count e fleet_or_private.

O principal desafio identificado para a classificação é o desbalanceamento da variável alvo.

Por esse motivo, a acurácia não deve ser utilizada isoladamente como medida de desempenho.

Métricas como precisão, recall, F1-score e ROC-AUC podem fornecer uma avaliação mais adequada.

Como algoritmos iniciais, podem ser avaliados Regressão Logística, Random Forest e métodos de Gradient Boosting.

6 CONSIDERAÇÕES FINAIS

A análise exploratória permitiu identificar características importantes do conjunto de dados, incluindo valores ausentes em baixa proporção, presença de valores extremos, fortes relações entre determinadas variáveis e desbalanceamento da variável alvo utilizada na classificação.

O pré-processamento foi estruturado de forma a preservar a maior quantidade possível de informação.

Foram utilizadas imputação pela mediana para variáveis numéricas, imputação pela moda para variáveis categóricas, *One-Hot Encoding* e padronização das variáveis numéricas.

Os outliers foram mantidos por poderem representar situações reais de operação e degradação das baterias.

Para regressão, os resultados indicaram forte relação da vida útil restante da bateria com atributos relacionados à tensão, condição térmica, perda de capacidade e estado de saúde.

Para classificação, características relacionadas à perda de capacidade, saúde, envelhecimento e comportamento elétrico apresentaram associação relevante com a ocorrência de falhas.

Entre os principais desafios identificados estão a multicolinearidade, a possível presença de relações não lineares e o desbalanceamento das classes.

Esses fatores devem orientar tanto a seleção de atributos quanto a escolha dos algoritmos e das métricas de avaliação em etapas futuras de modelagem.

A atividade permitiu integrar diferentes etapas de um fluxo de ciência de dados, desde a compreensão inicial do conjunto até sua preparação e a formulação de recomendações para problemas de aprendizado supervisionado.

7 REFERÊNCIA AO REPOSITÓRIO

Todo o código desenvolvido para esta atividade será disponibilizado em um repositório público no GitHub.

LINK DO REPOSITÓRIO

O repositório foi organizado em diretórios destinados aos dados, notebooks, funções auxiliares, figuras e documentação.

A estrutura adotada busca separar as diferentes etapas do processo de análise e facilitar a reprodutibilidade do trabalho.

O diretório notebooks/ contém quatro notebooks executados de acordo com a sequência das etapas da atividade.

O arquivo 01_eda.ipynb contém a análise exploratória; 02_preprocessing.ipynb reúne as etapas de limpeza e pré-processamento; 03_regression_analysis.ipynb apresenta a análise direcionada ao problema de regressão; e 04_classification_analysis.ipynb contém as análises relacionadas ao problema de classificação.

O diretório src/ contém funções auxiliares para carregamento dos dados, análise exploratória, pré-processamento e geração de visualizações.

Os gráficos produzidos durante as análises estão armazenados em reports/figures/, enquanto o relatório técnico final é disponibilizado no diretório docs/.