UNIVERSIDADE FEDERAL DO RIO GRANDE DO NORTE

DEPARTAMENTO DE COMPUTAÇÃO E TECNOLOGIA
BACHARELADO EM SISTEMAS DE INFORMAÇÃO

Avaliação Comparativa de Modelos: Sistema Especialista, Árvore de Decisão e Ensemble Learning

Isabelle Cavalcanti da Silva

Matrícula: 20250031684

Dataset:
https://www.kaggle.com/datasets/sarveshchhetri/ev-battery-failure-prediction-dataset-200k

Repositório GitHub:
https://github.com/Isabellecavalcant/projeto-ia-ev-battery

DCT1401 — Inteligência Artificial

Docente: Thommas K. S. Flores

Caicó – RN

2026

Sumário

1 Introdução **2**

2 Dados e protocolo experimental **2**

2.1 Fonte e características do conjunto de dados 2

2.2 Divisão entre treino e teste 3

2.3 Pré-processamento 4

2.4 Ambiente computacional 4

2.5 Modelos avaliados 7

2.6 Validação cruzada e seleção de hiperparâmetros 7

3 Sistema especialista **8**

3.1 Base de conhecimento 8

3.2 Amostra de regra 8

3.3 Motor de inferência 8

3.4 Cronometragem e medições de inferência 9

3.5 Tempo de elaboração das regras 9

4 Resultados de regressão **9**

4.1 Análise de sensibilidade e possível vazamento 13

4.2 Visualização e interpretação da árvore de regressão 14

5 Resultados de classificação **15**

5.1 Matriz de confusão 20

6 Ensemble Learning **23**

6.1 Curva de erro do Random Forest 23

6.2 Importância das variáveis 25

7 Eficiência computacional **25**

8 Discussão **25**

9 Conclusão **26**

10 Referência ao repositório **27**

1 Introdução

A manutenção preditiva de baterias de veículos elétricos pode apoiar decisões de inspeção, substituição e monitoramento. A identificação antecipada de condições associadas a falhas pode contribuir para a segurança e para o planejamento da manutenção, enquanto a estimativa da vida útil restante pode auxiliar na avaliação do estado de utilização dos componentes.

O objetivo deste trabalho é comparar diferentes abordagens de inteligência artificial aplicadas a duas tarefas relacionadas ao estado de baterias de veículos elétricos. São avaliados um sistema especialista baseado em regras, árvores de decisão e métodos de ensemble learning.

A primeira tarefa consiste em estimar a vida útil restante da bateria, representada pela variável `predicted_remaining_life_cycles`. Trata-se de um problema de regressão, pois o resultado esperado é um valor numérico contínuo ou discreto em ciclos.

A segunda tarefa consiste em identificar a ocorrência de falha, representada pela variável `battery_failure`. Trata-se de um problema de classificação binária, no qual a classe positiva corresponde à presença de falha.

A comparação considera não apenas o desempenho preditivo, mas também a capacidade de generalização, a complexidade, a interpretabilidade e o custo computacional. Busca-se, assim, identificar quais abordagens são mais adequadas a cada tarefa e quais limitações devem ser consideradas antes de uma possível aplicação prática.

2 Dados e protocolo experimental

2.1 Fonte e características do conjunto de dados

O conjunto de dados utilizado foi o *EV Battery Failure Prediction Dataset (200K)*, disponibilizado no Kaggle:

https://www.kaggle.com/datasets/sarveshchhetri/ev-battery-failure-prediction-dataset-200k

O conjunto bruto possui 200.000 registros e 70 colunas. Os identificadores `vehicle_id` e `battery_serial` foram removidos da modelagem.

Para a tarefa de regressão, foram excluídas as linhas sem o valor do alvo `predicted_remaining_li` e a coluna `battery_failure` foi removida das variáveis preditoras.

Para a classificação, foram excluídas as linhas sem o valor do alvo `battery_failure`, e a coluna `predicted_remaining_life_cycles` foi removida das variáveis preditoras.

Essa separação busca evitar que o modelo receba diretamente o outro alvo como variável de entrada. Entretanto, a exclusão direta das duas colunas não garante, por si só, a ausência de vazamento indireto, pois outras variáveis podem ter sido geradas a partir de informações relacionadas ao alvo.

2.2 Divisão entre treino e teste

A divisão dos dados foi realizada na proporção de 80% para treinamento e 20% para teste, utilizando a semente 42. Na classificação, foi utilizada estratificação para preservar aproximadamente a proporção das classes nas duas partições.

O conjunto de teste foi reservado para a avaliação final dos modelos. O ajuste de hiperparâmetros foi conduzido no conjunto de treinamento, de modo a reduzir o risco de selecionar modelos com base no desempenho observado nos dados de teste.

Na classificação, aproximadamente 90,04% dos registros pertencem à classe sem falha e 9,96% à classe com falha. Esse desbalanceamento torna inadequado avaliar os modelos exclusivamente pela acurácia. Por esse motivo, também são consideradas precisão, recall, F1, ROC-AUC e PR-AUC.

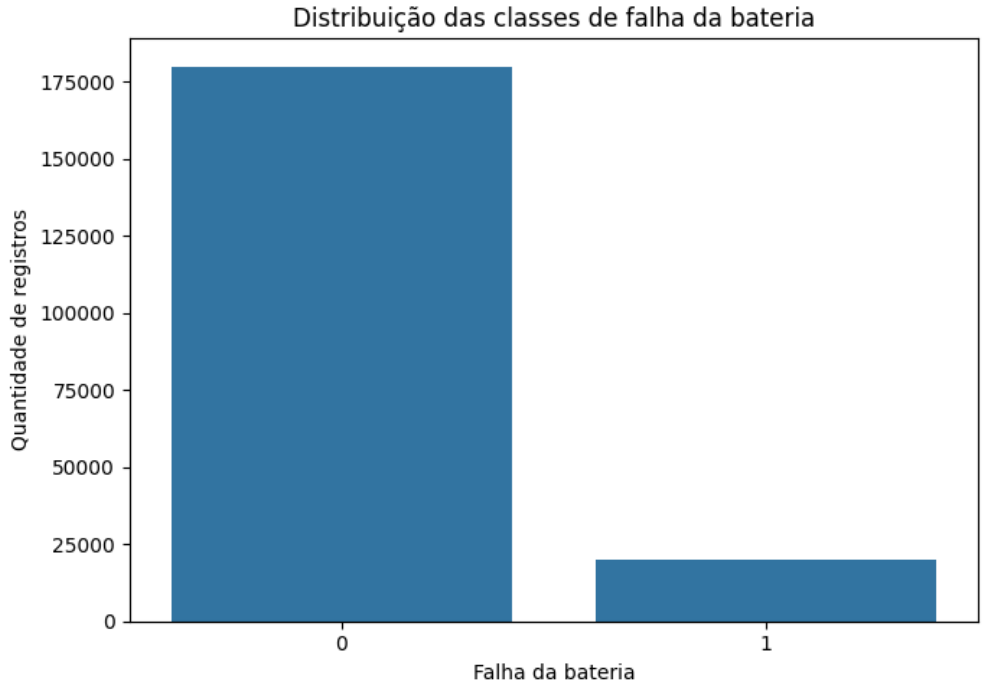


Figura 1: Distribuição das classes da variável de falha da bateria.

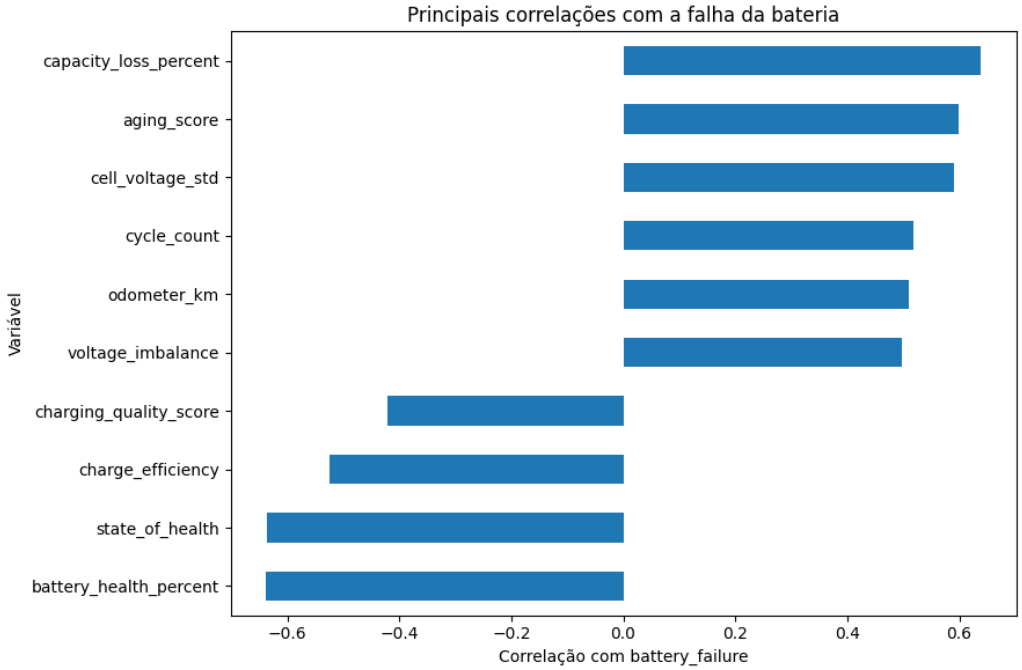


Figura 2: Correlação entre as variáveis utilizadas na classificação.

2.3 Pré-processamento

O pré-processamento foi implementado utilizando pipelines, com imputação e transformação das variáveis numéricas e categóricas. Os parâmetros das transformações devem ser ajustados exclusivamente a partir dos dados de treinamento, evitando que informações do conjunto de teste influenciem o processo de aprendizagem.

As métricas apresentadas neste relatório correspondem aos resultados registrados nos artefatos experimentais do projeto. A reprodução exata depende da execução do código com as mesmas versões das bibliotecas, sementes e configurações.

2.4 Ambiente computacional

Os experimentos foram executados localmente em um ambiente Ubuntu, utilizando Python 3.12 e um ambiente virtual denominado `.venv`. O ambiente reportou oito CPUs lógicas e aproximadamente 7,5 GiB de memória disponível.

O modelo exato do processador, a versão do kernel e o inventário completo das versões das bibliotecas não estão documentados nos registros consultados. Portanto, essas informações não são especificadas aqui para evitar atribuir ao ambiente características que não foram confirmadas.

A implementação utiliza principalmente:

- **pandas e NumPy:** manipulação e preparação dos dados;
- **scikit-learn:** pré-processamento, validação cruzada, árvores de decisão e ensembles;
- **Matplotlib:** geração de gráficos;

- **joblib:** persistência de modelos e artefatos.

Para garantir a reprodutibilidade, recomenda-se manter no repositório um arquivo de dependências com as versões efetivamente utilizadas, além de instruções para instalação e execução dos experimentos.

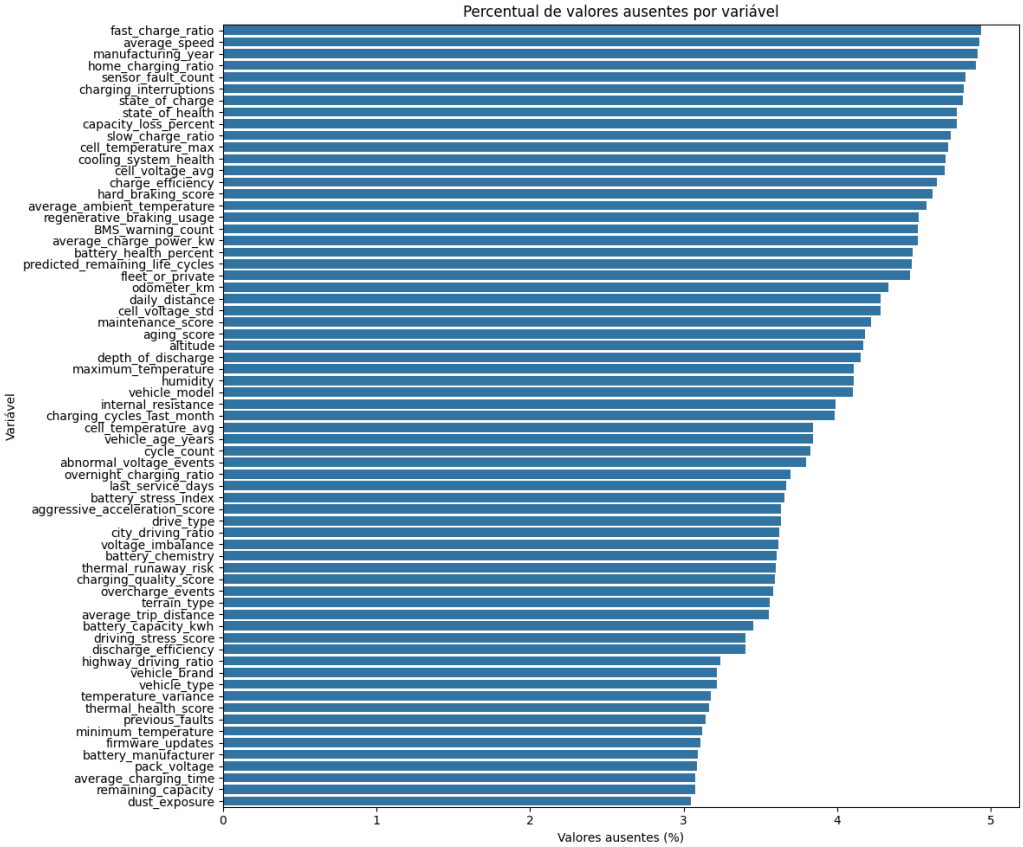


Figura 3: Visualização dos valores ausentes no conjunto de dados.

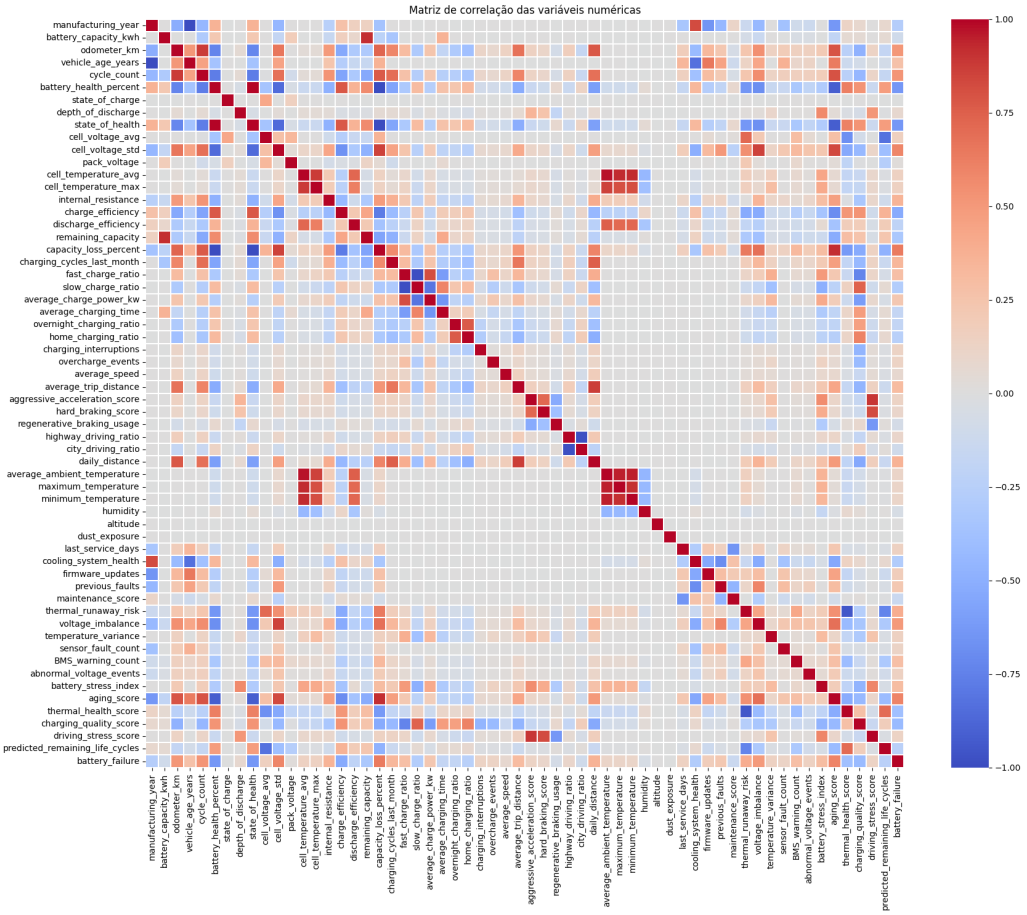


Figura 4: Matriz de correlação das variáveis do conjunto de dados.

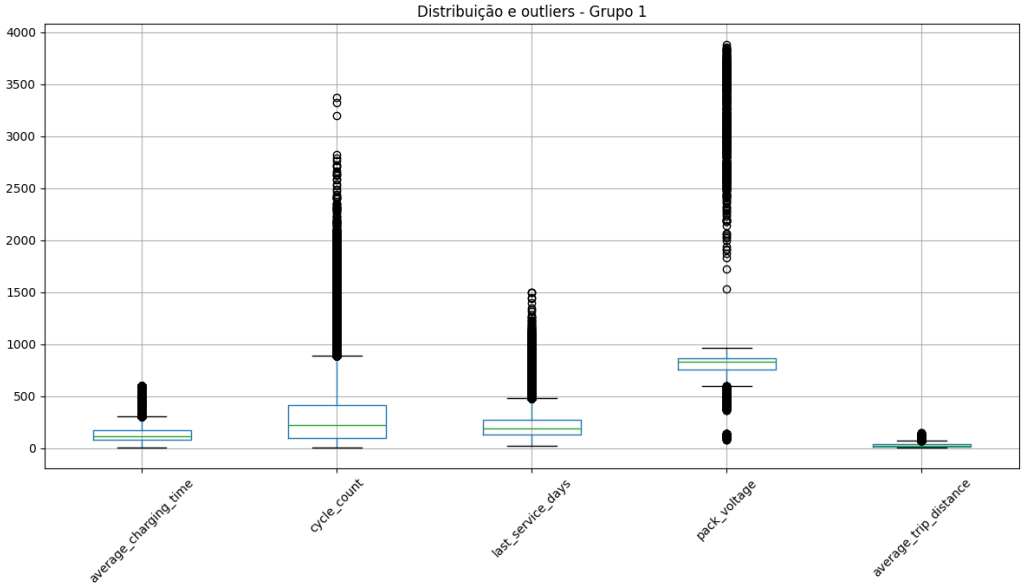


Figura 5: Distribuição e possíveis valores atípicos nas variáveis.

2.5 Modelos avaliados

Foram avaliados os seguintes modelos:

1. sistema especialista baseado em regras heurísticas;
2. árvore de decisão irrestrita;
3. árvore de decisão com hiperparâmetros ajustados;
4. Random Forest;
5. Gradient Boosting.

A árvore irrestrita permite observar o comportamento de um modelo com maior liberdade para ajustar os dados de treinamento. A árvore ajustada utiliza restrições de complexidade para reduzir o risco de sobreajuste. Os métodos de ensemble combinam múltiplos estimadores para melhorar o desempenho preditivo.

2.6 Validação cruzada e seleção de hiperparâmetros

A validação cruzada foi utilizada no conjunto de treinamento para comparar configurações e selecionar hiperparâmetros. Para a regressão, o RMSE foi utilizado como métrica de erro; para a classificação, foi utilizado o F1.

Os resultados da validação cruzada não devem ser confundidos com os resultados do teste. Os primeiros auxiliam a seleção do modelo, enquanto os segundos avaliam o desempenho na partição reservada.

Tabela 1: Configurações selecionadas para os modelos

Modelo	Configuração registrada
Árvore ajustada	Regressão: critério `squared_error`, profundidade máxima 10 e mínimo de 10 amostras por folha. Classificação: Gini, profundidade máxima 8 e mínimo de 50 amostras por folha.
Random Forest	Regressão: 50 árvores, `max_features`=0,3 e mínimo de 10 amostras por folha. Classificação: 200 árvores, profundidade máxima 20, `max_features`=0,3 e mínimo de 3 amostras por folha.
Gradient Boosting	Regressão: 50 estimadores, taxa de aprendizado 0,2 e mínimo de 50 amostras por folha. Classificação: 200 estimadores, profundidade 3, taxa de aprendizado 0,1 e mínimo de 50 amostras por folha.

Na comparação específica de critérios da árvore de classificação, Gini apresentou F1 médio de validação cruzada de 0,7181, enquanto entropia apresentou 0,7099.

Na comparação de critérios da árvore de regressão, os critérios `squared_error` e `friedman_mse` produziram o mesmo escore registrado, de aproximadamente $-278{,}3024$. Esse valor corresponde ao escore negativo retornado pela convenção de maximização do scikit-learn para a métrica de erro e pertence à comparação de critérios. Ele não deve ser interpretado como o RMSE final dos modelos selecionados.

3 Sistema especialista

3.1 Base de conhecimento

O sistema especialista utiliza regras heurísticas para produzir estimativas de vida útil restante e identificar condições associadas à falha da bateria.

A base de conhecimento é mantida em arquivos de texto separados do mecanismo de inferência. Essa separação permite modificar as regras sem alterar a implementação do motor.

As regras de classificação consideram condições relacionadas a risco térmico, variação de tensão, perda de capacidade, resistência interna, histórico de falhas e estado de saúde da bateria.

As regras de regressão associam faixas de saúde, perda de capacidade, envelhecimento e ciclos a estimativas discretas de vida útil restante. Quando nenhuma regra aplicável produz uma conclusão, o sistema utiliza o valor padrão definido na base de conhecimento. Para a regressão, o valor padrão registrado é 1.246 ciclos.

As regras são heurísticas e não devem ser consideradas conhecimento especializado certificado. Seu desempenho precisa ser validado empiricamente antes de qualquer utilização operacional.

3.2 Amostra de regra

Uma regra de classificação registrada no projeto apresenta a seguinte estrutura:

```
R01 | heurística | SE capacity_loss_percent > 30 E cell_voltage_std > 0.03
| ENTÃO battery_failure = 1
```

A regra indica que, quando a perda de capacidade ultrapassa 30% e o desvio de tensão das células é superior a 0,03, o sistema conclui que há falha.

Esse exemplo ilustra a estrutura SE–ENTÃO, mas não demonstra que os limiares utilizados sejam clinicamente, industrialmente ou fisicamente validados. Eles devem ser entendidos como heurísticas adotadas na implementação.

3.3 Motor de inferência

O motor de inferência lê os arquivos de regras, valida sua estrutura e interpreta os operadores de comparação. Para cada amostra, as premissas são avaliadas a partir dos atributos disponíveis.

Quando as condições de uma regra são satisfeitas, sua conclusão é acrescentada aos fatos inferidos. Nas regras conectadas por `E`, todas as condições precisam ser verdadeiras. Nas regras conectadas por `OU`, basta que uma condição seja verdadeira.

O mecanismo utiliza encadeamento para frente e não sobrescreve fatos de entrada já existentes. Valores ausentes e comparações incompatíveis são tratados como condições

não satisfeitas. Caso nenhuma regra conclua o alvo, aplica-se o valor padrão definido na base.

O sistema também registra a quantidade de disparos por regra. Essa informação permite avaliar a cobertura da base de conhecimento e identificar regras pouco utilizadas ou que concentram a maior parte das inferências.

3.4 Cronometragem e medições de inferência

As medições consolidadas do projeto registram os seguintes tempos médios de inferência por amostra:

Tabela 2: Tempo de inferência do sistema especialista

Tarefa	Tempo médio por amostra (ms)
Classificação	0,0203
Regressão	0,0165

3.5 Tempo de elaboração das regras

O log bruto disponível contém duas sessões de elaboração de regras de classificação, com durações de 64,8 segundos e 75,3 segundos. Considerando essas duas observações, o tempo total registrado é de 140,1 segundos, equivalente a aproximadamente 2,34 minutos, e a média é de 70,05 segundos por sessão.

Existe uma inconsistência entre esse log bruto e o resumo agregado, que registra apenas uma sessão. Por isso, os cálculos foram feitos a partir das duas linhas do log bruto.

Não foi localizado um registro equivalente para o tempo de elaboração das regras de regressão. Consequentemente, não é possível comparar de forma confiável o esforço de construção das duas bases. Essa ausência constitui uma limitação da avaliação e não deve ser preenchida com valores estimados sem fundamento experimental.

4 Resultados de regressão

A regressão busca estimar o valor de `predicted_remaining_life_cycles`. As métricas utilizadas incluem MAE, RMSE, MAPE, coeficiente de determinação R^2 e erro absoluto mediano.

O MAE representa a média dos erros absolutos. O RMSE penaliza de forma mais intensa erros de maior magnitude. O MAPE expressa o erro percentual médio, mas apresenta limitações quando os valores reais são iguais ou próximos de zero. O R^2 indica a proporção da variabilidade do alvo explicada pelo modelo em relação a uma referência baseada na média.

Tabela 3: Resultados de regressão no conjunto de teste

Modelo	MAE	RMSE	MAPE (%)	R^2	MedAE	CV RMSE
Árvore irrestrita	47,81	86,19	4,42	0,99774	34,00	124,60 ± 6,94
Árvore ajustada	48,61	110,55	4,85	0,99628	34,48	116,58 ± 12,57
Random Forest	37,01	79,30	3,84	0,99809	25,48	82,68 ± 2,43
Gradient Boosting	39,86	81,90	4,30	0,99796	28,27	97,74 ± 4,39
Sistema especialista	943,23	1656,91	57,06	0,16492	592,00	–

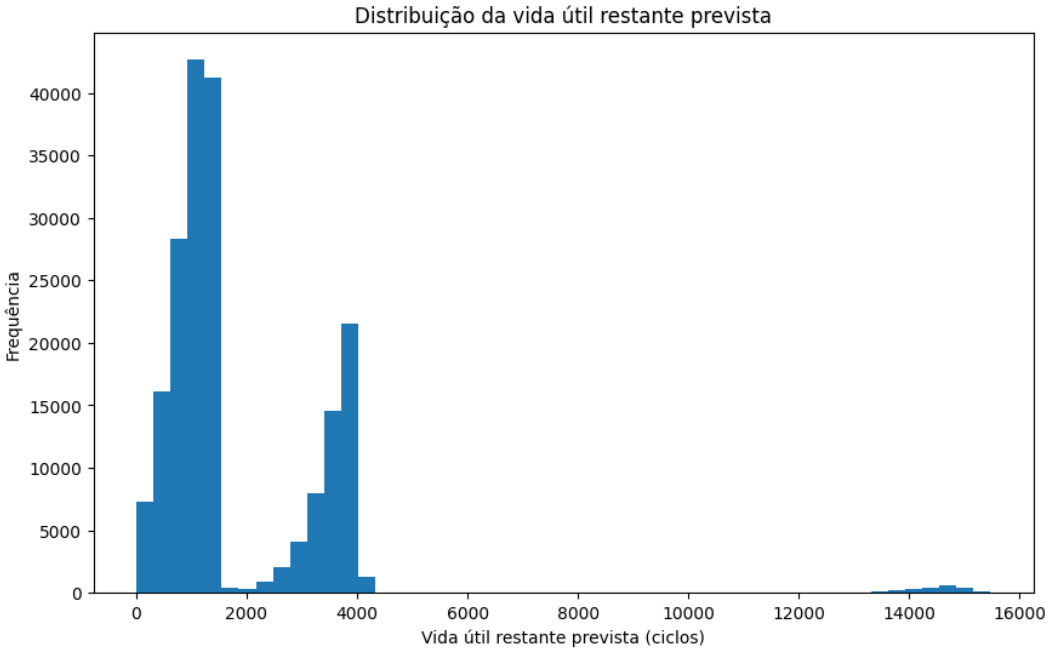


Figura 6: Distribuição da variável-alvo da tarefa de regressão.

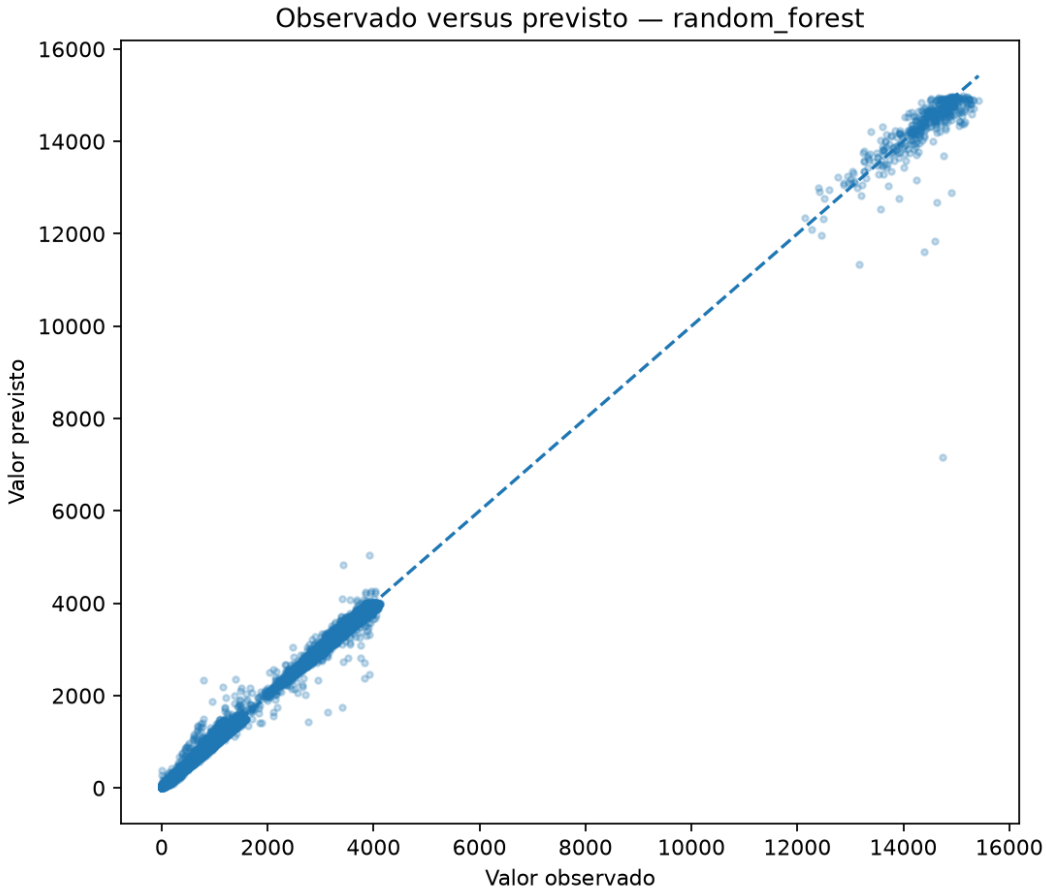


Figura 7: Valores observados e previstos pelo Random Forest na regressão.

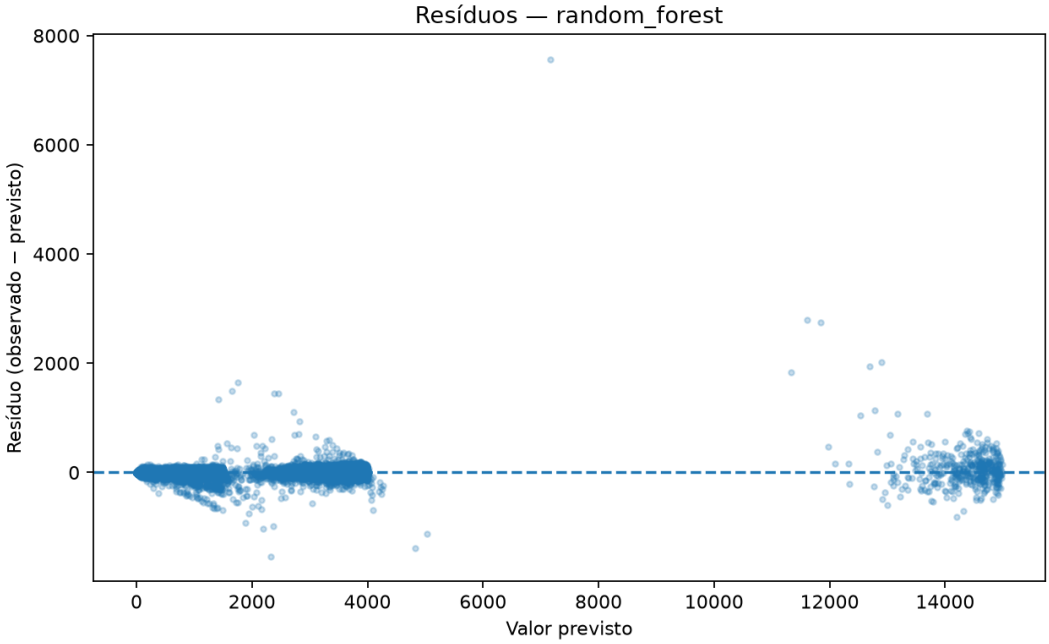


Figura 8: Análise dos resíduos do Random Forest na regressão.

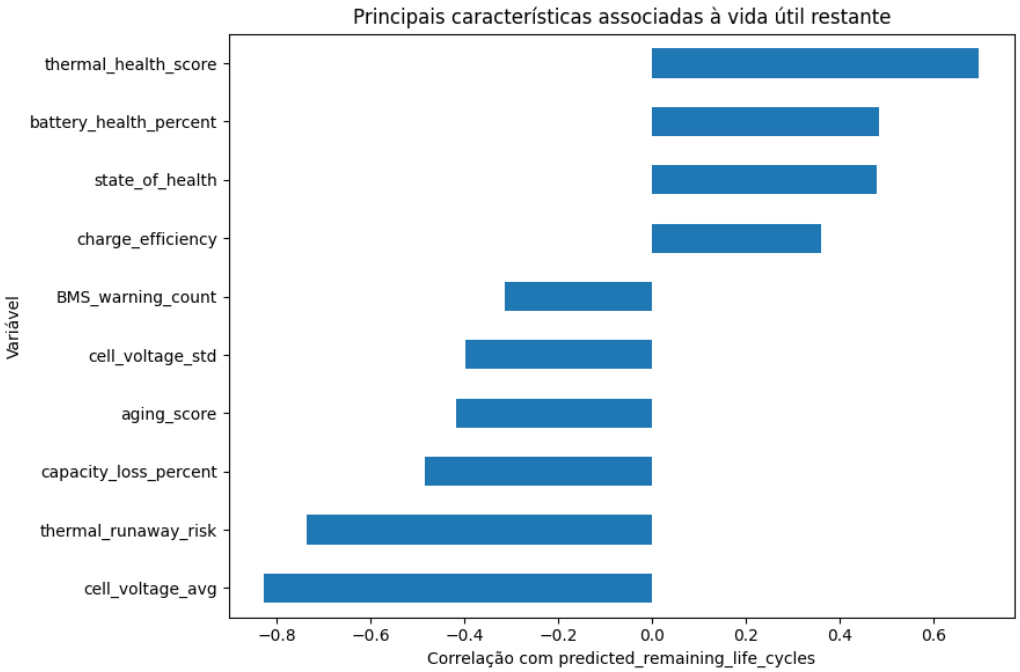


Figura 9: Correlação entre as variáveis relacionadas à tarefa de regressão.

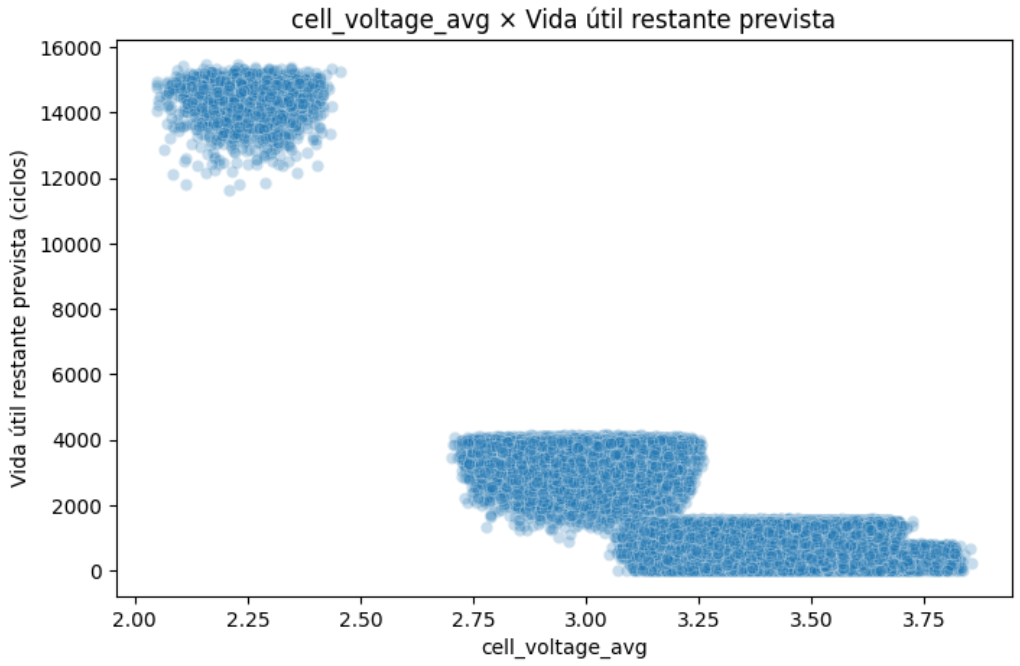


Figura 10: Dispersão relacionada à tensão das células na tarefa de regressão.

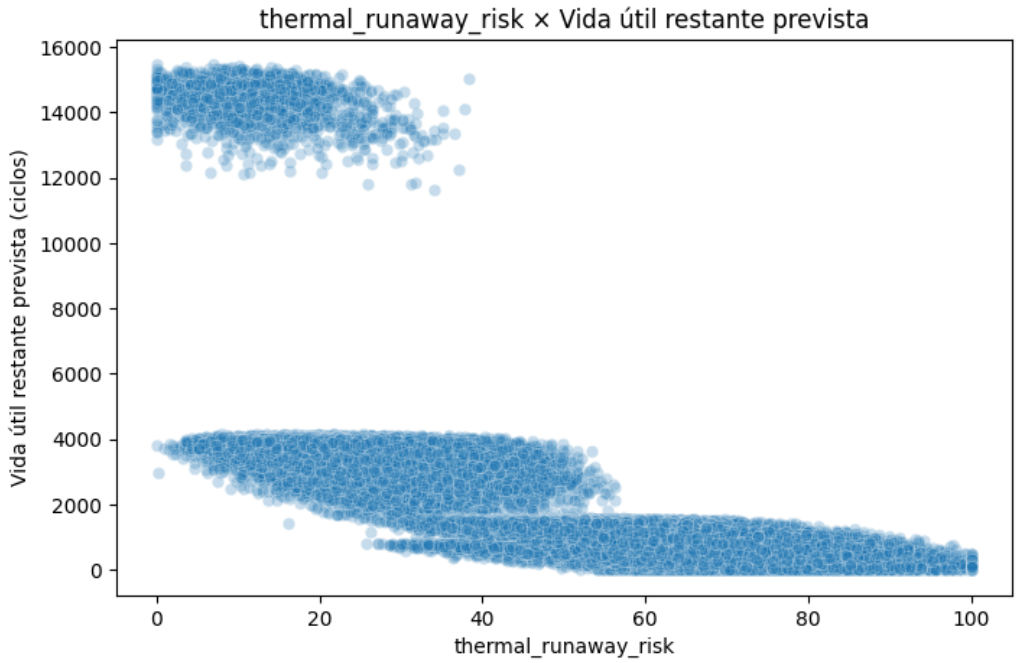


Figura 11: Dispersão relacionada ao risco térmico na tarefa de regressão.

O Random Forest obteve o menor MAE e RMSE no teste, com MAE de 37,01 ciclos e RMSE de 79,30 ciclos. O Gradient Boosting apresentou resultados próximos, com RMSE de 81,90 ciclos.

A árvore irrestrita apresentou RMSE de teste inferior ao da árvore ajustada, mas esse resultado não elimina o risco de sobreajuste. A árvore irrestrita ajustou perfeitamente os dados de treinamento, o que indica que sua estrutura pode ter aprendido particularidades da amostra de treino que não se repetem na mesma proporção em dados não observados.

O sistema especialista apresentou erro significativamente superior ao dos modelos aprendidos. Esse resultado é compatível com o uso de regras heurísticas simples e estimativas discretas para representar uma variável que possui ampla variação.

O MAPE exclui observações cujo alvo real é zero: 207 observações do teste e 903 do treino. Por isso, o MAPE deve ser interpretado em conjunto com o MAE e o RMSE, e não como uma medida isolada.

4.1 Análise de sensibilidade e possível vazamento

Foi conduzido um experimento de sensibilidade utilizando Random Forest, comparando a configuração com todas as variáveis disponíveis com uma configuração que removeu três variáveis altamente correlacionadas com o alvo: `cell_voltage_avg`, `thermal_runaway_risk` e `thermal_health_score`.

Tabela 4: Análise de sensibilidade da regressão

Experimento	MAE	RMSE	R^2	Treino (s)
Todas as variáveis	34,27	71,46	0,99845	105,62
Sem as três variáveis	36,82	102,57	0,99680	96,73

A remoção das variáveis aumentou o RMSE de 71,46 para 102,57 ciclos e reduziu o R^2 de 0,99845 para 0,99680. Isso demonstra que as variáveis removidas têm influência importante no desempenho do modelo.

Entretanto, a piora das métricas não comprova, por si só, vazamento do alvo. Para chegar a essa conclusão, seria necessário investigar como as variáveis foram produzidas, se utilizam informações futuras e se foram calculadas direta ou indiretamente a partir do alvo.

Além disso, os valores dessa análise diferem dos resultados da tabela principal. Eles devem ser interpretados como um experimento de sensibilidade separado, e não como substitutos das métricas dos modelos finais.

4.2 Visualização e interpretação da árvore de regressão

A árvore de decisão permite examinar os atributos e limiares utilizados para produzir estimativas. Entretanto, árvores irrestritas podem se tornar muito extensas, dificultando a interpretação manual e aumentando o risco de sobreajuste.

A árvore ajustada restringe a profundidade e o número mínimo de amostras por folha, favorecendo uma estrutura menor. Essa redução de complexidade pode facilitar a inspeção, embora não garanta desempenho superior em todas as métricas.

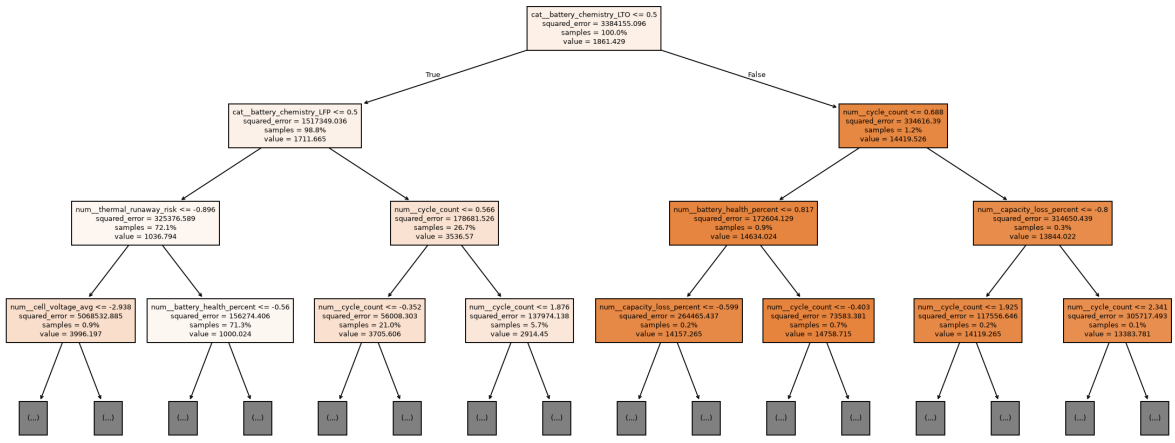


Figura 12: Visualização da árvore de decisão para regressão.

5 Resultados de classificação

A classificação busca prever a variável binária `battery_failure`. Como a classe positiva representa aproximadamente 9,96% dos registros, a análise enfatiza o F1, o recall e a PR-AUC, além da acurácia.

A precisão mede a proporção de previsões positivas que correspondem a falhas reais. O recall mede a proporção de falhas reais identificadas. O F1 combina precisão e recall por meio da média harmônica. A ROC-AUC avalia a capacidade de ordenação entre as classes, enquanto a PR-AUC enfatiza o desempenho na identificação da classe positiva.

Tabela 5: Resultados de classificação no conjunto de teste

Modelo	Acurácia	Precisão	Recall	F1	ROC-AUC	PR-AUC	CV F1
Árvore irrestrita	0,94178	0,70641	0,71084	0,70862	0,83908	0,53095	0,70385 ± 0,00547
Árvore ajustada	0,95293	0,78963	0,71888	0,75260	0,97354	0,83670	0,74950 ± 0,00817
Random Forest	0,96273	0,84828	0,76205	0,80286	0,98610	0,90075	0,80103 ± 0,00418
Gradient Boosting	0,96663	0,85386	0,80221	0,82723	0,98910	0,92005	0,82802 ± 0,00483
Sistema especialista	0,91195	0,57026	0,47063	0,51568	0,71778	0,36490	–

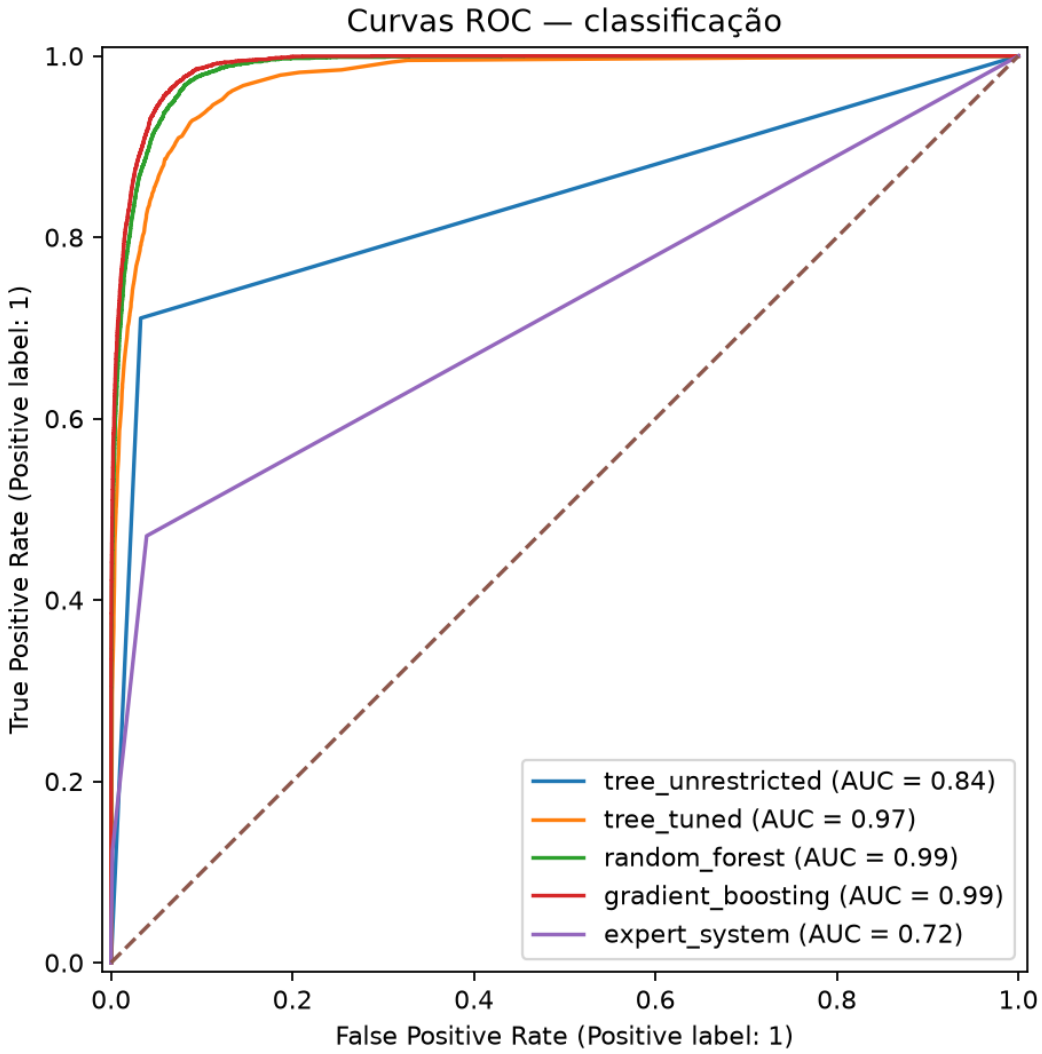


Figura 13: Curvas ROC dos modelos de classificação.

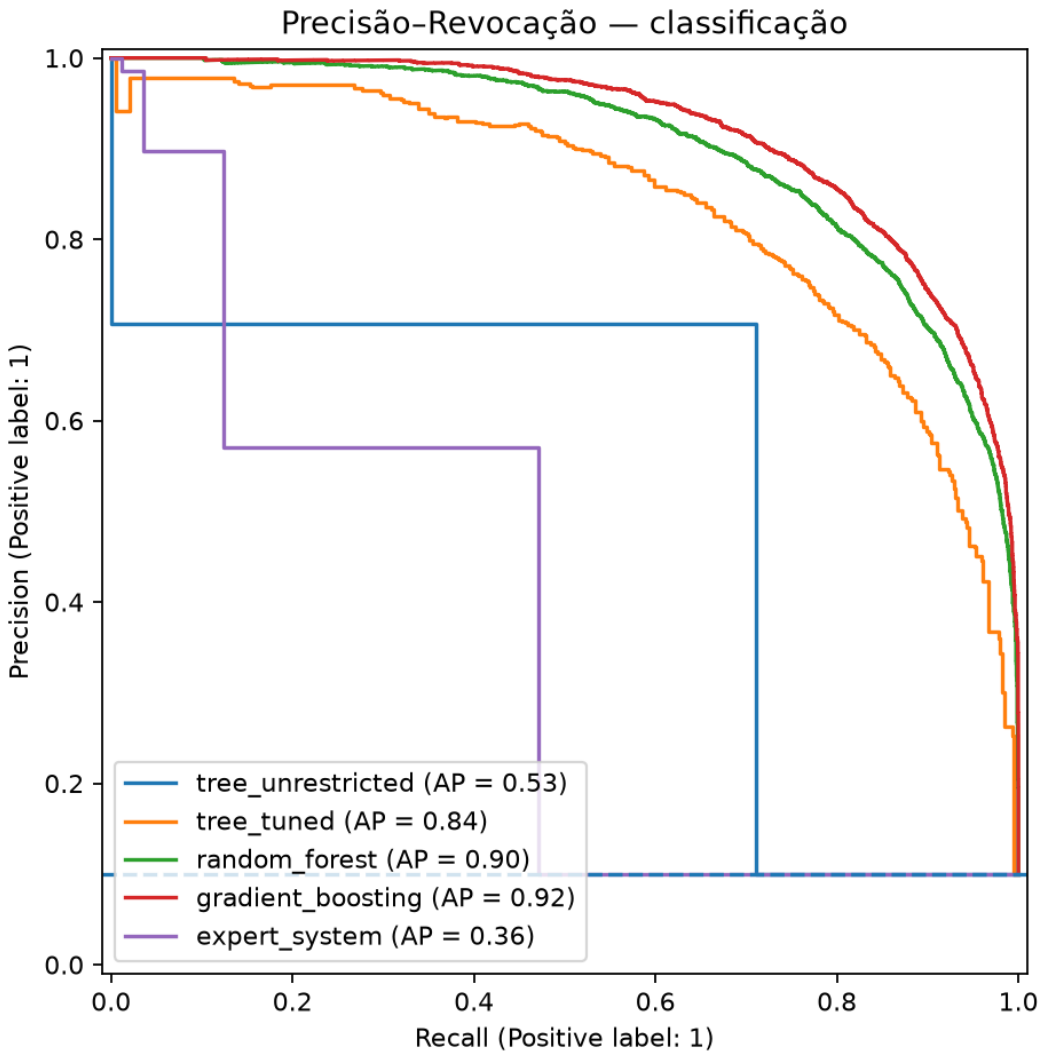


Figura 14: Curvas precisão-recall dos modelos de classificação.

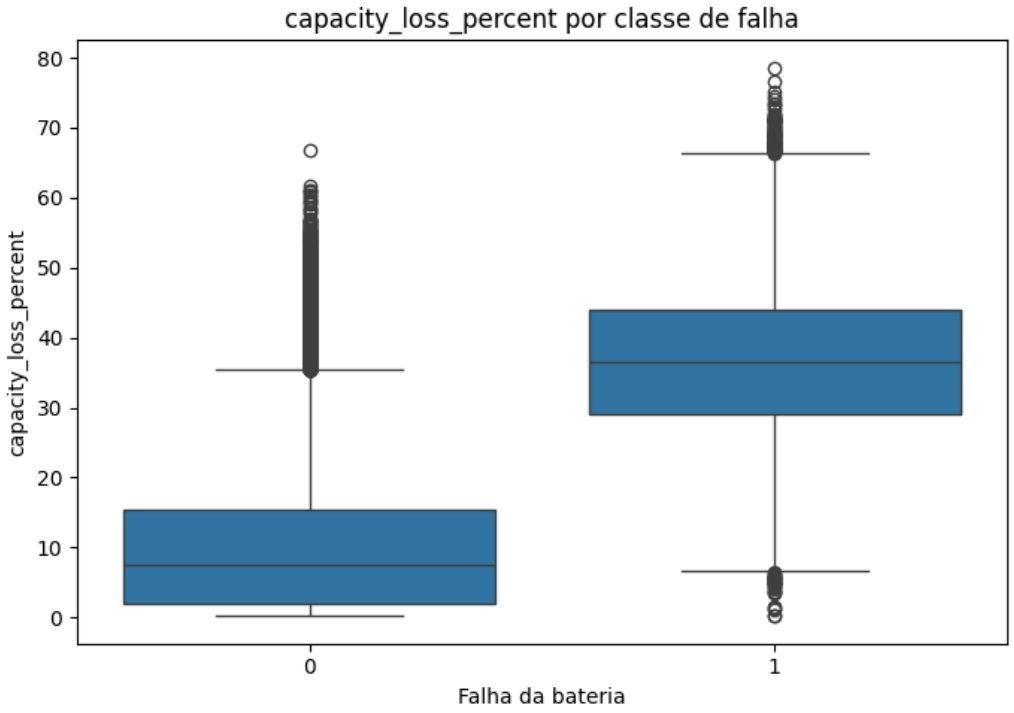


Figura 15: Distribuição da perda de capacidade por classe na classificação.

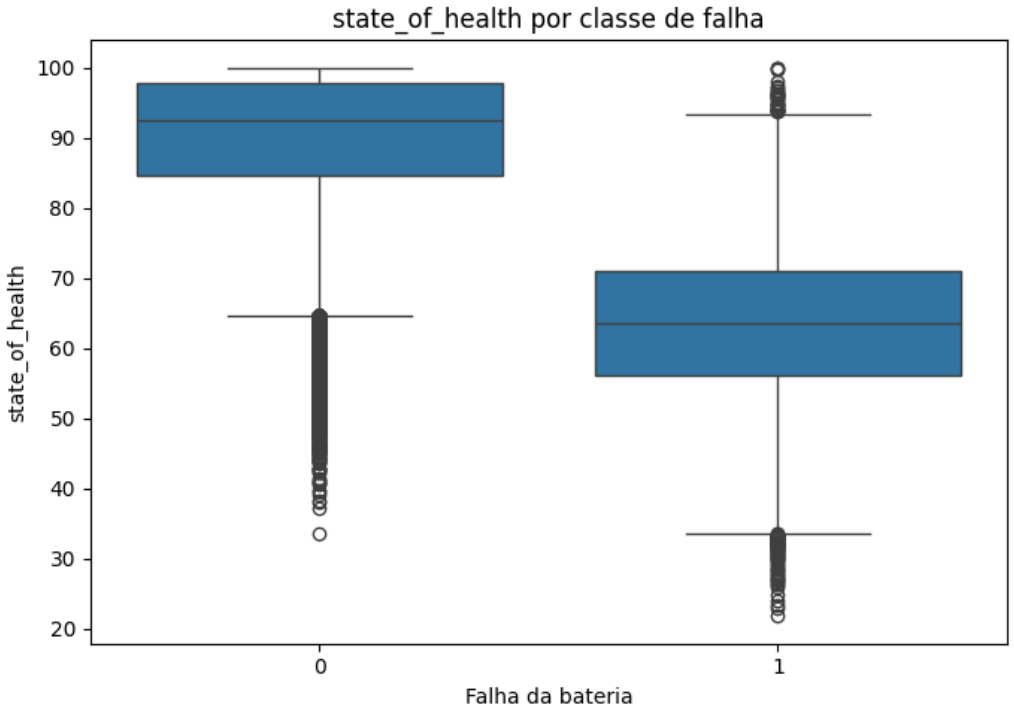


Figura 16: Distribuição do estado de saúde da bateria por classe.

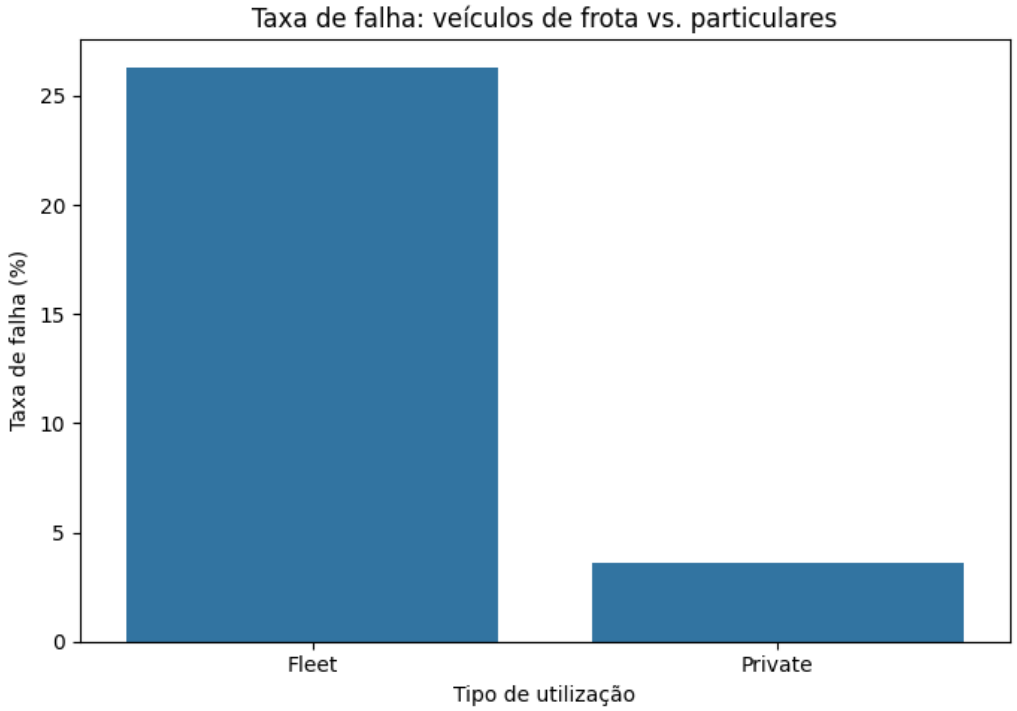


Figura 17: Visualização complementar das falhas no conjunto de classificação.

O Gradient Boosting apresentou os melhores resultados gerais de classificação, com F1 de 0,82723, recall de 0,80221, ROC-AUC de 0,98910 e PR-AUC de 0,92005.

O Random Forest apresentou F1 de 0,80286, ficando em segundo lugar. A árvore ajustada teve F1 de 0,75260, enquanto a árvore irrestrita apresentou F1 de 0,70862 no teste.

A árvore irrestrita alcançou métricas perfeitas no conjunto de treinamento, mas seu F1 caiu para 0,70862 no teste. Essa diferença é um indício claro de sobreajuste e reforça a importância de avaliar o comportamento do modelo em dados não utilizados no ajuste.

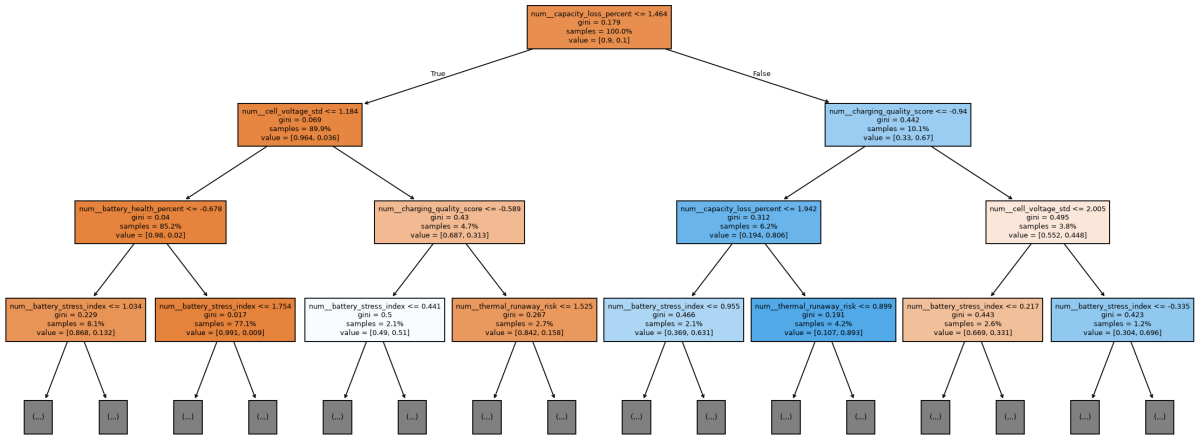


Figura 18: Visualização da árvore de decisão para classificação.

5.1 Matriz de confusão

A matriz de confusão do Gradient Boosting no conjunto de teste contém:

Tabela 6: Matriz de confusão do Gradient Boosting

	Previsto: sem falha	Previsto: falha
Real: sem falha	35.469	547
Real: falha	788	3.196

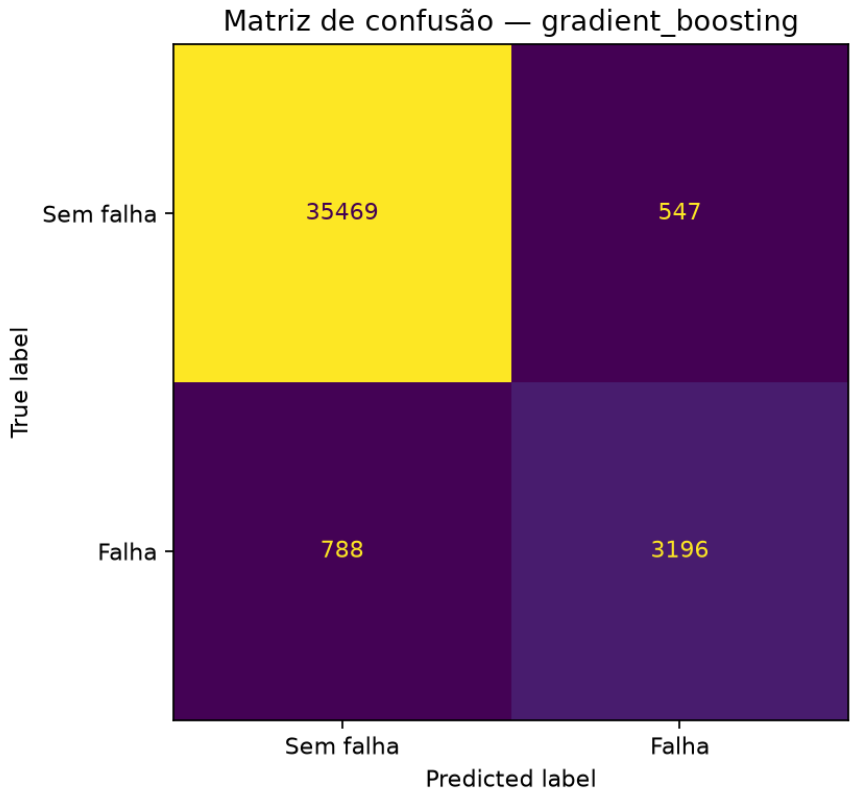


Figura 19: Visualização gráfica da matriz de confusão do Gradient Boosting.

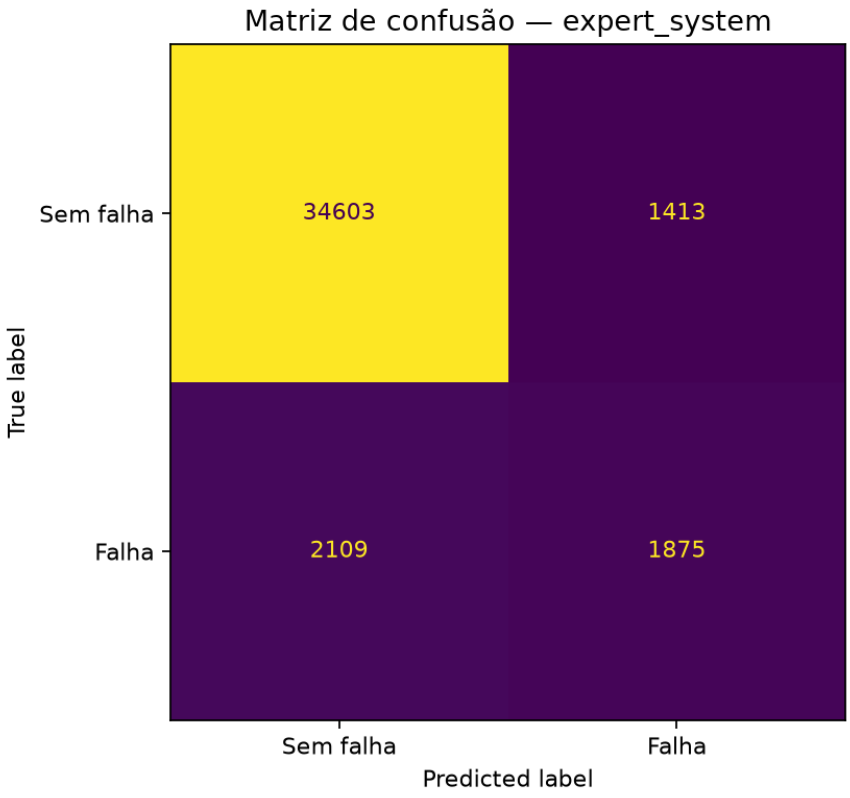


Figura 20: Matriz de confusão do sistema especialista.

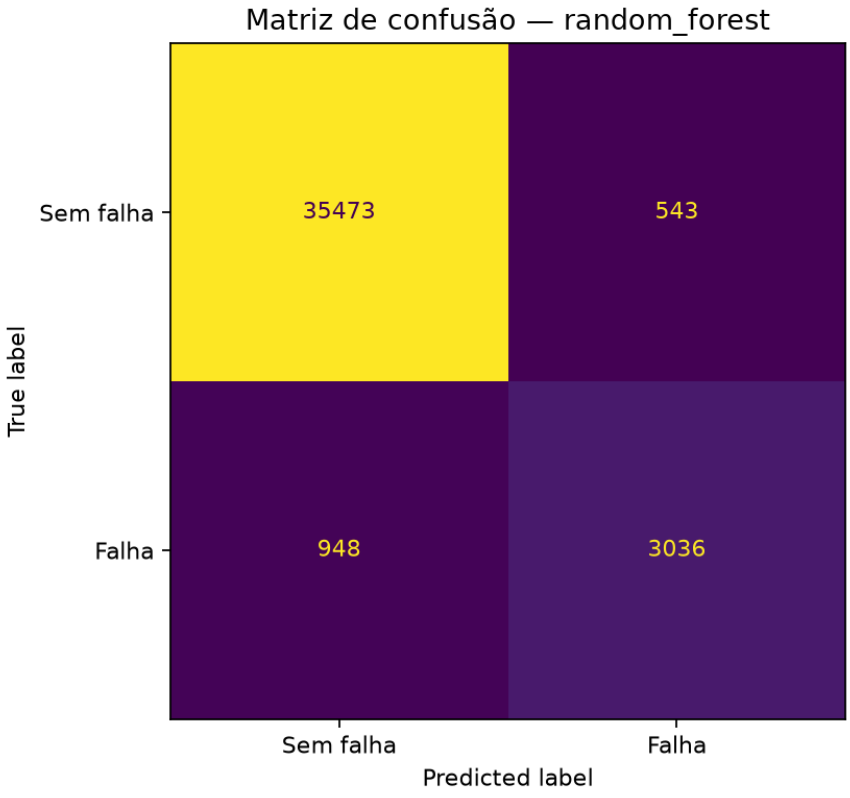


Figura 21: Matriz de confusão do Random Forest.

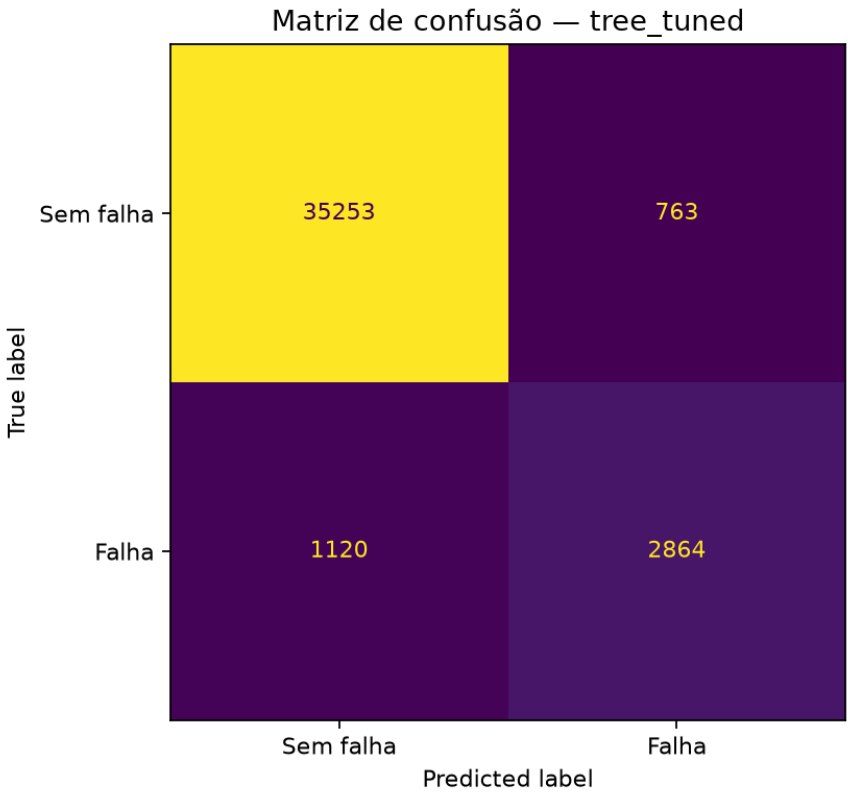


Figura 22: Matriz de confusão da árvore ajustada.

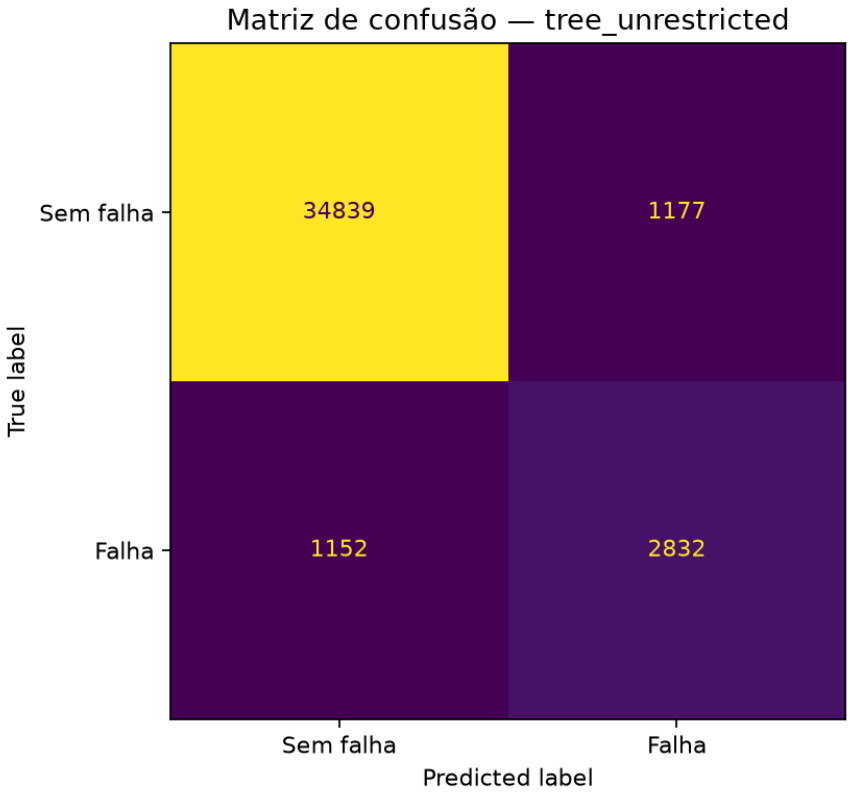


Figura 23: Matriz de confusão da árvore irrestrita.

O modelo identificou 3.196 falhas corretamente, mas deixou de identificar 788 casos positivos. O recall de 0,80221 indica que aproximadamente 80,2% das falhas reais foram detectadas.

Em aplicações relacionadas à segurança, falsos negativos podem ser particularmente importantes, pois representam falhas não identificadas pelo modelo. Assim, mesmo com métricas elevadas, a implantação exigiria análise dos custos de erro, validação externa e definição de um limiar de decisão apropriado.

Como aproximadamente 90% dos registros pertencem à classe sem falha, um classificador que previsse sempre ausência de falha poderia obter acurácia próxima de 90%, embora não identificasse nenhuma falha. Isso justifica a utilização de F1, recall e PR-AUC como medidas complementares.

6 Ensemble Learning

Foram avaliados dois métodos de ensemble: Random Forest e Gradient Boosting.

O Random Forest combina previsões de múltiplas árvores treinadas com aleatoriedade nos dados e nas variáveis consideradas. Essa combinação tende a reduzir a variabilidade de uma árvore individual, embora aumente o custo de armazenamento e inferência.

O Gradient Boosting constrói uma sequência de estimadores, em que cada etapa procura corrigir parte dos erros da combinação anterior. O resultado depende de fatores como número de estimadores, profundidade, taxa de aprendizado e tamanho mínimo das folhas.

6.1 Curva de erro do Random Forest

O número de árvores influencia o custo computacional e o desempenho preditivo. Em geral, aumentar o número de árvores eleva o custo de treinamento e armazenamento, mas pode melhorar a estabilidade das previsões. O ganho tende a diminuir após determinado ponto, embora esse comportamento dependa do conjunto de dados e dos hiperparâmetros.

Na classificação, o erro de validação registrado diminuiu de 0,3088 com uma árvore para 0,1978 com 200 árvores. No mesmo intervalo, o erro de treinamento diminuiu de 0,1551 para 0,0263.

A diferença entre erro de treinamento e erro de validação mostra que o desempenho no conjunto de treino não deve ser usado isoladamente para selecionar o número de árvores. A redução mais discreta do erro de validação entre 100 e 200 árvores indica retornos decrescentes nesse intervalo.

Na regressão, o erro de validação caiu de 226,80 com uma árvore para aproximadamente 80–81 com 30–50 árvores. Como os registros disponíveis não incluem pontos de 100 e 200 árvores para regressão, não se extrapola a tendência além dos valores observados.

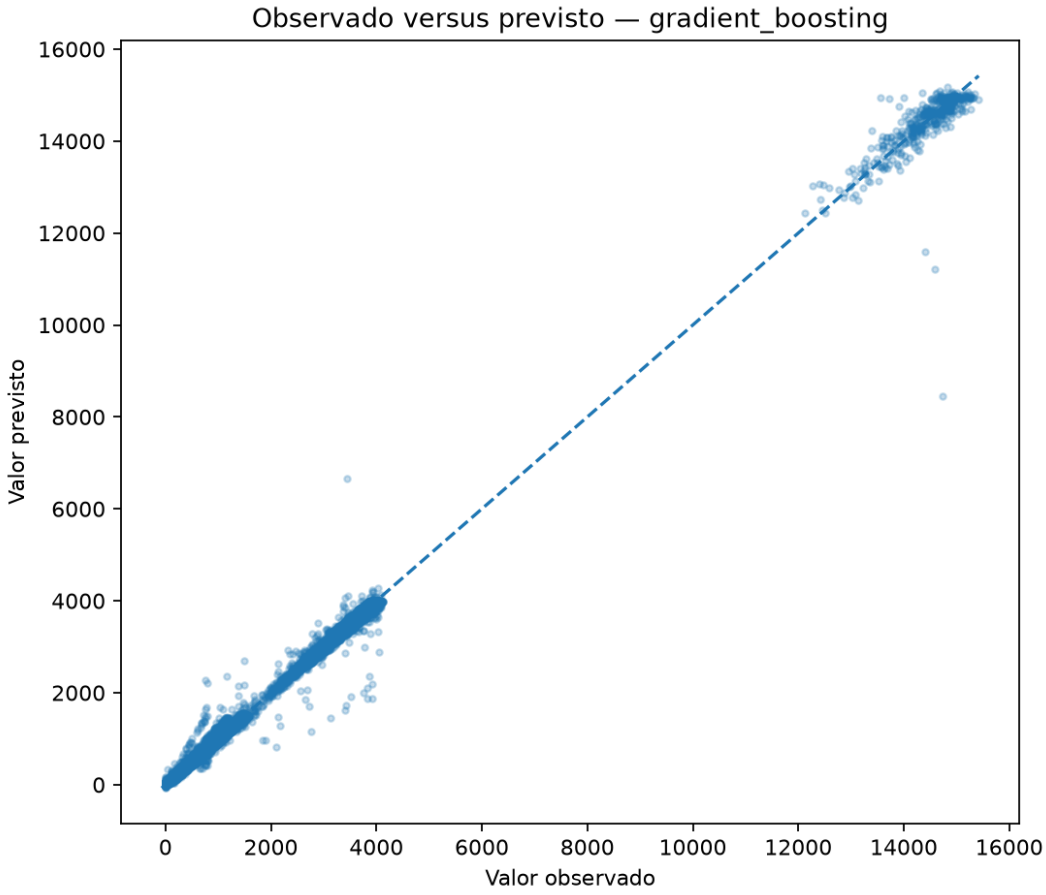


Figura 24: Valores observados e previstos pelo Gradient Boosting na regressão.

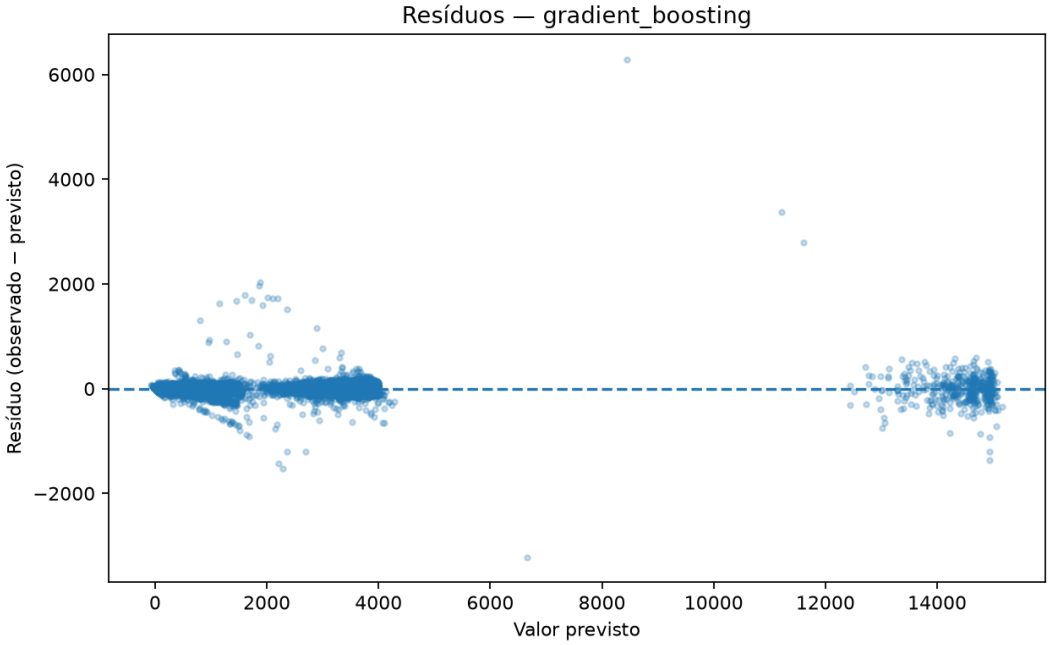


Figura 25: Análise dos resíduos do Gradient Boosting na regressão.

6.2 Importância das variáveis

A importância das variáveis permite examinar quais atributos mais contribuíram para as decisões internas dos modelos de árvore e ensemble.

A importância baseada na redução de impureza indica quanto uma variável contribuiu para as divisões das árvores. Entretanto, ela não demonstra causalidade e pode favorecer variáveis contínuas ou variáveis correlacionadas entre si.

A análise deve considerar a tarefa e o modelo. As variáveis mais importantes para classificar falhas não precisam ser as mesmas utilizadas para estimar a vida útil restante.

Neste relatório, a importância das variáveis é discutida de forma conceitual. A análise quantitativa deve considerar os arquivos de resultados disponibilizados no repositório do projeto.

7 Eficiência computacional

A eficiência computacional foi analisada a partir do tempo de treinamento, do tempo de inferência, da complexidade dos modelos e do tamanho dos arquivos serializados.

Tabela 7: Tempo de treinamento e complexidade dos modelos

Tarefa	Modelo	Treino (s)	Profundidade	Complexidade
Regressão	Árvore irrestrita	12,00	60	286.233 nós
Regressão	Árvore ajustada	6,30	10	993 nós
Regressão	Random Forest	24,49	48	50 árvores
Regressão	Gradient Boosting	4,33	15	50 estimadores
Classificação	Árvore irrestrita	14,45	29	7.719 nós
Classificação	Árvore ajustada	6,72	8	419 nós
Classificação	Random Forest	173,80	20	200 árvores
Classificação	Gradient Boosting	8,13	3	200 estimadores

As árvores individuais apresentaram os menores tempos médios de inferência. Os ensembles exigem a avaliação de múltiplos estimadores, aumentando o custo de previsão. O sistema especialista também apresentou tempos maiores que as árvores individuais nas medições registradas, embora sua estrutura baseada em regras seja conceitualmente simples.

O tamanho em disco reforça que o custo de um modelo não depende apenas de sua métrica preditiva. O Random Forest de classificação apresentou tamanho consideravelmente maior que os demais modelos, enquanto a árvore ajustada foi mais compacta.

8 Discussão

Na classificação, a árvore irrestrita apresentou métricas perfeitas no treino, mas F1 de 0,70862 no teste. Esse comportamento sugere sobreajuste. A árvore ajustada reduziu a

complexidade, enquanto os ensembles obtiveram resultados de teste superiores.

Na regressão, a árvore irrestrita também ajustou perfeitamente os dados de treinamento, mas apresentou erro de teste diferente de zero. O Random Forest apresentou o menor RMSE de teste e um desvio-padrão de validação cruzada relativamente pequeno, indicando desempenho mais consistente nas partições avaliadas.

As árvores individuais apresentaram os menores tempos de inferência. A árvore ajustada também apresentou tamanho reduzido, o que a torna atraente em dispositivos com memória limitada ou quando a explicabilidade é prioritária.

Quando a interpretabilidade, o armazenamento reduzido e a facilidade de inspeção forem prioridades, a árvore ajustada pode ser uma alternativa, aceitando-se a perda de desempenho observada.

9 Conclusão

Este trabalho comparou um sistema especialista, árvores de decisão, Random Forest e Gradient Boosting em duas tarefas relacionadas a baterias de veículos elétricos.

Na regressão, o Random Forest obteve o melhor resultado no teste, com MAE de 37,01 ciclos, RMSE de 79,30 ciclos e $R^2 = 0,99809$. Na classificação, o Gradient Boosting apresentou o melhor resultado, com F1 de 0,82723, recall de 0,80221 e PR-AUC de 0,92005.

A árvore irrestrita apresentou sinais de sobreajuste, enquanto a árvore ajustada ofereceu uma estrutura menor e mais fácil de inspecionar. Os ensembles apresentaram desempenho preditivo superior, mas exigem a consideração de custos computacionais e de armazenamento.

O sistema especialista teve desempenho inferior, mas evidenciou a vantagem de regras explícitas e inspecionáveis. A experiência também mostrou que regras heurísticas precisam ser avaliadas sistematicamente e que sua interpretabilidade não garante, por si só, precisão ou confiabilidade.

Entre as principais limitações estão a ausência de documentação completa do hardware e das versões das bibliotecas, a falta de registros completos do tempo de elaboração das regras de regressão, a utilização de estimativas energéticas baseadas em potência fixa e a necessidade de investigar a origem das variáveis altamente correlacionadas com o alvo.

A análise de sensibilidade mostrou que algumas variáveis exercem influência importante no desempenho da regressão, mas não foi suficiente para confirmar vazamento de dados. Uma avaliação futura deve incluir auditoria da origem dos atributos, validação em dados externos e, quando possível, divisão por veículo, bateria ou período temporal.

Como aprendizado principal, os resultados reforçam que a seleção de um modelo de inteligência artificial não deve se basear exclusivamente em uma métrica. Desempenho preditivo, generalização, interpretabilidade, custo computacional, qualidade dos dados e consequências dos erros devem ser considerados em conjunto.

10 Referência ao repositório

O código-fonte, as regras e os artefatos experimentais estão disponíveis no repositório:

https://github.com/Isabellecavalcant/projeto-ia-ev-battery

A estrutura relevante do projeto inclui:

- `rules/`: arquivos de regras do sistema especialista;
- `logs/`: registros de cronometragem;
- `reports/tables/`: tabelas de métricas, hiperparâmetros, curvas e importância das variáveis;
- `reports/figures/`: gráficos e visualizações exportados;
- `reports/predictions/`: previsões salvas para análise posterior.

Os resultados apresentados foram consolidados a partir dos artefatos experimentais registrados no projeto. Para facilitar a reprodução integral, recomenda-se manter instruções de instalação e execução, as sementes utilizadas, as versões das bibliotecas e os comandos necessários para gerar novamente as tabelas e figuras.

Referências

[1] CHHETRI, Sarvesh. *EV Battery Failure Prediction Dataset (200K)*. Kaggle. Disponível em: https://www.kaggle.com/datasets/sarveshchhetri/ev-battery-failure-predicti Acesso em: 26 out. 2026.

[2] PEDREGOSA, F. et al. Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, v. 12, p. 2825–2830, 2011.

[3] SCIKIT-LEARN. *User Guide*. Disponível em: https://scikit-learn.org/stable/user_guide.html. Acesso em: 26 out. 2026.